DE LA RECHERCHE À L'INDUSTRIE

Architecture d'un cluster

philippe.gregoire@cea.fr

www.cea.fr

Architecture d’un super-calculateur
Agenda

Introduction au calcul haute performance

Présentation d’un centre de calcul

Utilisation d’un super-calculateur

Composantes principales d'un super-calculateur

Administration / maintenance

Les challenges à venir

Introduction
au
Calcul Haute Performance (HPC)

Le calcul haute performance (HPC)

- **Résolution de problèmes scientifiques complexes nécessitant une très grande quantité de calculs informatiques**
  - Expériences virtuelles remplaçant des expérimentations
    - trop coûteuses (accidents, crash tests),
    - trop longues (climatologie)
    - trop courtes,(physique atomique)
    - trop petites (protéines)
    - trop grandes (formation des étoiles, des galaxies),
    - Interdites (essais nucléaires, essais sur des êtres vivants)
    - Manipulant généralement de gros volumes de données
  -
  - Énergie nucléaire, Défense, Imagerie médicale, Fusion nucléaire, Médecine personnalisée, Climat, Astrophysique …
  - Ex Jumeau numérique
  - Ex DEUS : https://www.dailymotion.com/video/xyh1ih#.UWL3zRlsYqo

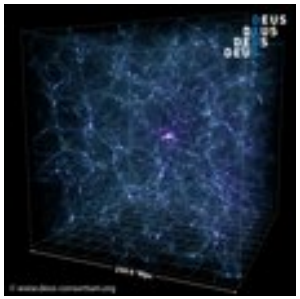

- **Utilisation des technologies informatiques les plus avancées**
  - Logicielles et matérielles
  - Afin de maximiser les performances et de réduire les délais de résolution
- **Notion de super-calculateur fournissant les ressources nécessaires**
  - Le terme HPC fait généralement référence au terme *supercomputer*
- **Mise en œuvre d'algorithmes de calcul complexes et adaptés aux architectures des super-calculateurs**
  - Permettant d'optimiser les applications pour maximiser les rendements de calcul

Les super-calculateurs

- **Machines conçues afin de maximiser les performances de calcul**
  - Classification des performances via la notion de quantité d'opérations en virgule flottante par seconde (Flops/s)

- **Les premiers super-calculateurs datent des années 60**
  - Machines CDC (Control Data Corporation), conçues par Seymour Cray
    - Spécifiquement définies pour les besoins du calcul scientifique
    - Alors 10x plus puissantes que les machines concurrentes pour ces tâches

1959 - CDC 1604

1964 - CDC 6400

1969 - CDC 7600

Introduction au Calcul Haute Performance

MAINFRAME

IBM 7030

1963…

MAINFRAME

CDC 6400

1970…

VECTORIEL

CRAY 1S

1982…

VECTORIEL

CRAY YMP

1990…

MASSIVEMENT PARALLELE

CRAY T3D

1993 ...

VECTORIEL

CRAY T90

1996…

Introduction au Calcul Haute Performance

MASSIVEMENT PARALLELE

Cray T3E

1995…

MASSIVEMENT PARALLELE

SiliconGraphics Origin2000

2000…

CLUSTER PARALLELE

DEC TERA 1

2001…

CLUSTER PARALLELE

Bull Tera 10

2006…

CLUSTER PARALLELE

Bull Tera 100

2010…

CLUSTER PARALLELE

Bull Tera 1000

2017…

Les super-calculateurs

- **Très dépendants des technologies matérielles qui leur sont contemporaines**
  - L'objet désigné par le terme évolue donc au cours du temps
- **Aujourd'hui, un super-calculateur est dans la majorité des cas**
  - Une grappe de machines de calcul (cluster) et d'espaces de stockage fédérés au travers d'un ou plusieurs réseaux à haut débit et faible latence
  - Une machine fortement parallèle nécessitant des algorithmes de calcul adaptés

1997 – ASCI Red (Intel)

2008 – RoadRunner (IBM)

2012 – K (Fujitsu)

Les métriques associées

Puissance de calcul

- **La puissance de calcul s'exprime généralement en Flop/s (ou Flops)**
  - nombre d'opérations en virgule flottante par seconde

$$\text{FLOPS} = \text{cœurs} \times \text{fréquence} \times \frac{\text{FLOP}}{\text{cycle}}.$$

Ex : processeur AMD 64 coeurs 2,4 Ghz = 64 * 2,4 * 4 = 640 Gflops

  - GigaFlops (GF) = 10^9 : domaine de puissance des processeurs actuels (qq 100)
    - Milliard d'opérations /seconde
  - TéraFlops (TF) = 10^{12} : puissance atteinte par un supercalculateur en 1997 (ASCI Red)
    - Mille milliards (1 Billion)
  - Pétaflops (PF) = 10^{15} : puissance atteinte par un supercalculateur en 2008 (RoadRunner)
    - Un million de millards (1 Billiard)
  - Exaflops (EF) = 10^{18} : puissance atteinte par un supercalculateur en mai 2022 (Frontier)
    - Un milliard de milliards (1 Trillion)

- La précision des flottants variant entre *single* (32 bits FP32) et *double* (64 bits FP64), il est important de comparer des puissances exprimées pour des précisions similaires

Les métriques associées

- Mémoire
  - La capacité mémoire s'exprime généralement en GigaOctets (Go) ou GigaBytes (GB)
  - Les développeurs regardent le ratio Go par Coeur
- Stockage disque
  - La capacité disque s'exprime généralement en TéraOctets (To) ou TeraBytes (TB)
  - Le débit IO s'exprime en Go/s ou To/s
- Réseau
  - Le débit s'exprime en Go/s, la latence s'exprime en µs
    - Réseau Infiniband
      - 2003 : 8Go/s => 2014 : 100Go/s
      - 2003 : 5 µs => 2014 0,5µs
- Consommation
  - Mégawatts
  - Frontier (ORNL) : 21 Mwatts ~ ville de plusieurs dizaines de milliers d'habitants
  - Émission de CO2

Le classement des supercalculateurs

- Deux concours par an, en juin et novembre
- Basé sur un code de benchmark Linpack
  - Peak perf = nb coeurs * (nb op /cycle) * (cycle / sec)
- 3 classements
  - HPL : High-Performance Linpack
    - Test de résolution d'équations unaires linéaires
    - Comparaison avec la puissance théorique de la machine
  - HPCG : High-Performance Conjugate Gradient
    - modèles d' accès aux données d'applications du monde réel
    - Complète HPL
  - Green500 :
    - Mesure l'efficacité énergétique de la machine
    - Classement par performance par Watt (GigaFlops/watt)

- **https://www.top500.org**

HPC Top 500 : Novembre 2022

Rank	System	Cores	Rmax (PFlop/s)	Rpeak (PFlop/s)	Power (kW)
1	**Frontier** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** DOE/SC/Oak Ridge National Laboratory **United States**	8,730,112	1,102.00	1,685.65	21,100
2	**Supercomputer Fugaku** - Supercomputer Fugaku, A64FX 48C 2.2GHz, Tofu interconnect D, **Fujitsu** RIKEN Center for Computational Science **Japan**	7,630,848	442.01	537.21	29,899
3	**LUMI** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** EuroHPC/CSC **Finland**	2,220,288	309.10	428.70	6,016
4	**Leonardo** - BullSequana XH2000, Xeon Platinum 8358 32C 2.6GHz, NVIDIA A100 SXM4 64 GB, Quad-rail NVIDIA HDR100 Infiniband, **Atos** EuroHPC/CINECA **Italy**	1,463,616	174.70	255.75	5,610
5	**Summit** - IBM Power System AC922, IBM POWER9 22C 3.07GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, **IBM** DOE/SC/Oak Ridge National Laboratory **United States**	2,414,592	148.60	200.79	10,096

HPC Top 500 : Top 10 Novembre 2022

6	**Sierra** - IBM Power System AC922, IBM POWER9 22C 3.1GHz, NVIDIA Volta GV100, Dual-rail Mellanox EDR Infiniband, **IBM / NVIDIA / Mellanox** DOE/NNSA/LLNL United States	1,572,480	94.64	125.71	7,438
7	**Sunway TaihuLight** - Sunway MPP, Sunway SW26010 260C 1.45GHz, Sunway, **NRCPC** National Supercomputing Center in Wuxi China	10,649,600	93.01	125.44	15,371
8	**Perlmutter** - HPE Cray EX235n, AMD EPYC 7763 64C 2.45GHz, NVIDIA A100 SXM4 40 GB, Slingshot-10, **HPE** DOE/SC/LBNL/NERSC United States	761,856	70.87	93.75	2,589
9	**Selene** - NVIDIA DGX A100, AMD EPYC 7742 64C 2.25GHz, NVIDIA A100, Mellanox HDR Infiniband, **Nvidia** NVIDIA Corporation United States	555,520	63.46	79.22	2,646
10	**Tianhe-2A** - TH-IVB-FEP Cluster, Intel Xeon E5-2692v2 12C 2.2GHz, TH Express-2, Matrix-2000, **NUDT** National Super Computer Center in Guangzhou China	4,981,760	61.44	100.68	18,482

HPC Green 500 : Top 10 Novembre 2022

Rank	TOP500 Rank	System	Cores	Rmax (PFlop/s)	Power (kW)	Energy Efficiency (GFlops/watts)
1	405	**Henri** - Lenovo ThinkSystem SR670 V2, Intel Xeon Platinum 8362 2800Mhz (32C), NVIDIA H100 80GB PCIe, Infiniband HDR, **Lenovo** Flatiron Institute **United States**	5,920	2.04	31	65.091
2	32	**Frontier TDS** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** DOE/SC/Oak Ridge National Laboratory **United States**	120,832	19.20	309	62.684
3	11	**Adastra** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** Grand Equipement National de Calcul Intensif - Centre Informatique National de l'Enseignement Suprieur (GENCI-CINES) **France**	319,072	46.10	921	58.021
4	15	**Setonix – GPU** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** Pawsey Supercomputing Centre, Kensington, Western Australia **Australia**	181,248	27.16	477	56.983
5	68	**Dardel GPU** - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, **HPE** KTH - Royal Institute of Technology **Sweden**	52,864	8.26	146	56.491

HPC Top 500 : autres stats 10 Novembre 2022

top500 novembre 2021

https://www.top500.org/statistics/list/

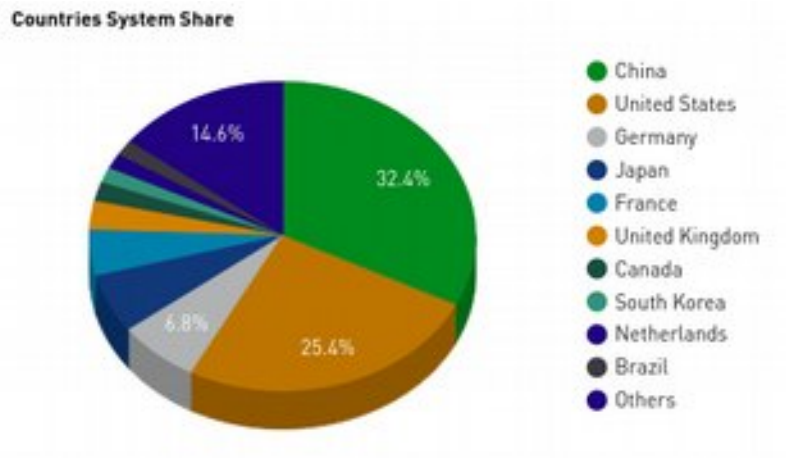

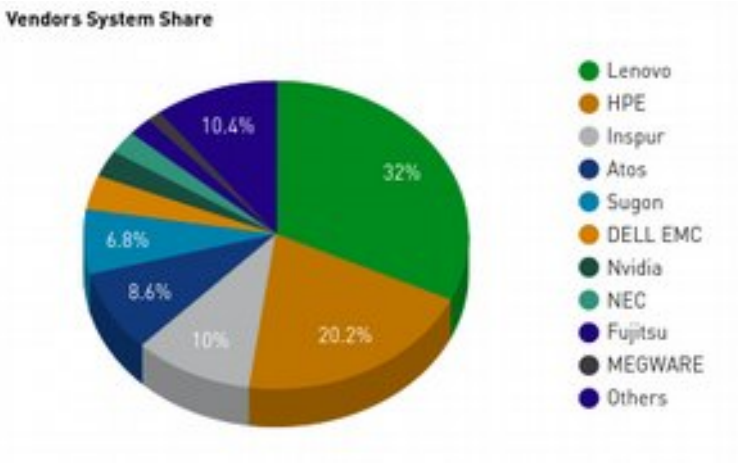

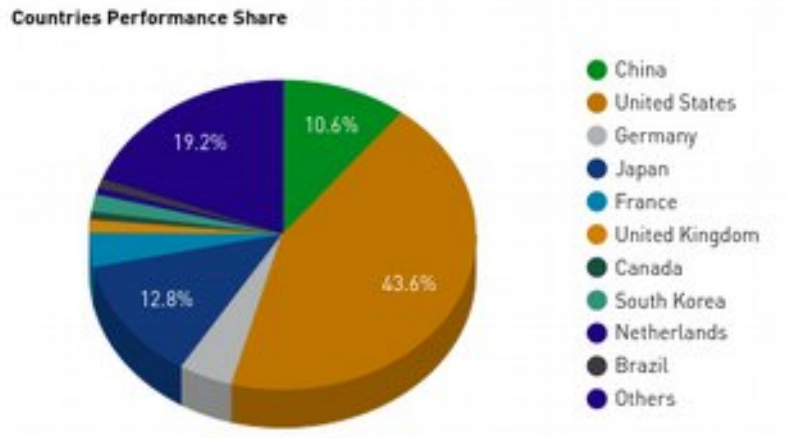

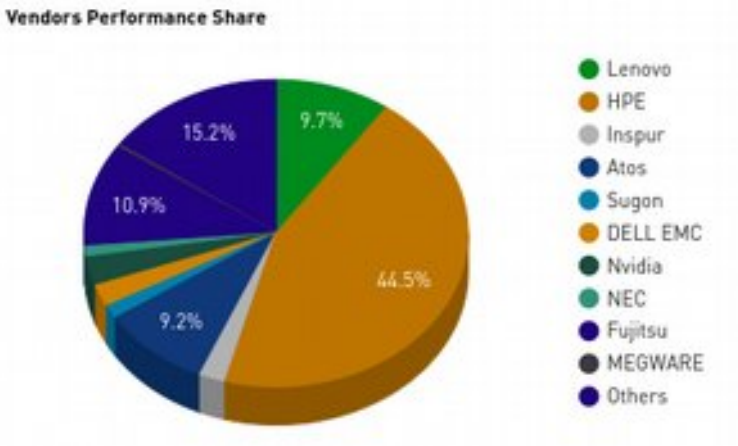

Introduction au Calcul Haute Performance

Le centre de calcul TERA

CEA/DAM

- Partition HF: 810 240 coeurs, 23 Pflop/s (#20)
  - 6330 noeuds bi-processeurs AMD Milan 7H13 (Epyc) à 2,45GHz, 64 coeurs, 256 Go de mémoire DDR4 / nœud,
  - Réseau d'interconnexion ATOS BXI V2
- Partition Tera1000-2 : 561408 coeurs, 192 GPUs, 17 Pflops GPU. (#49)
  - 8256 nœuds mono processeur Intel KNL 7250 à 1,4 GHz , 68 cœurs, 96 Go de mémoire DDR4 + 16 Go de mémoire MCDRAM/noeud,
  - Réseau d'interconnexion Atos-BULL BXI V1
- Partition xlarge
  - 4 nœuds bi-processeurs AMD Milan 7H13 (Epyc) à 2,45GHz, 64 coeurs, 4 To de mémoire DDR4, 1 GPUs NVIDIA A100
- Stockage Lustre 500 Go/s

CCRT: Topaze

- Partition AMD Milan: 110 592 coeurs, 4,5 Pflop/s (#170)
  - 864 noeuds bi-processeurs AMD Milan 7H13 (Epyc) à 2,45GHz, 64 coeurs, 256 Go de mémoire DDR4 / nœud,
  - Réseau d'interconnexion Infiniband HDR100
- Partition A100 : 6144 coeurs, 192 GPUs, 4,3 Pflops GPU. (#241)
  - 48 nœuds hybrides bi-processeurs AMD Milan 7H13 à 2,45GHz, 64 coeurs et 4 GPUs NVIDIA A100, 2 ports HDR100
- Partition xlarge
  - 4 nœuds bi-processeurs AMD Milan 7H13 (Epyc) à 2,45GHz, 64 coeurs, 4 To de mémoire DDR4, 1 GPUs NVIDIA A100
- Stockage Lustre 3 Po, 280 Go/s

TGCC : Irene Joliot-Curie

- Partition Intel Skylake : 79 488 cœurs, 6,86 Pflop/s (#133)
  - 1 656 nœuds bi-processeurs Intel Skylake 8168 à 2,7 GHz, 24 cœurs, 192 Go DDR4/noeud,
  - Réseau d'interconnexion Infiniband EDR.
- Partition Intel KNL : 56 304 cœurs, 2 Pflop/s
  - 828 nœuds mono processeur Intel KNL 7250 à 1,4 GHz , 68 cœurs, 96 Go de mémoire DDR4 + 16 Go de mémoire MCDRAM/noeud,
  - Réseau d'interconnexion Atos-BULL BXI.
- Partition AMD Rome : 293 376 coeurs, 11,75 Pflop/s (#83)
  - 2292 noeuds bi-processeurs AMD Rome (Epyc) à 2,6 GHz, 64 coeur, 256 Go de mémoire DDR4 / nœud,
  - Réseau d'interconnexion Infiniband HDR100 ?
- Partition V100 (traitement de données, IA)
  - 30 nœuds hybrides bi-processeurs Intel CascadeLake à 2.6 GHz, 18 coeurs et 1 GPU NVIDIA V100,
- Partition A64FX
  - FX700 : 80 nœuds de calcul DDR-less mono-socket A64FX
- Partitions hybride (visu), xlarge(pré/post traitement)
- Stockage Lustre 5 Po, 300 Go/s

Introduction au Calcul Haute Performance
La méthode de la simulation numérique

Le phénomène ou système :
- représentation du phénomène
- lois physiques

Le modèle :
- traduction en équations mathématiques
- prise en compte des /= grandeurs

La discrétisation :
- découpage spatiale par maille
- découpage temporelle par pas de temps
- résolution pour chaque maille

Le calcul
- préparation des données
- suivi des simulations

La comparaison avec l'expérience
- visualisation, graphe, film

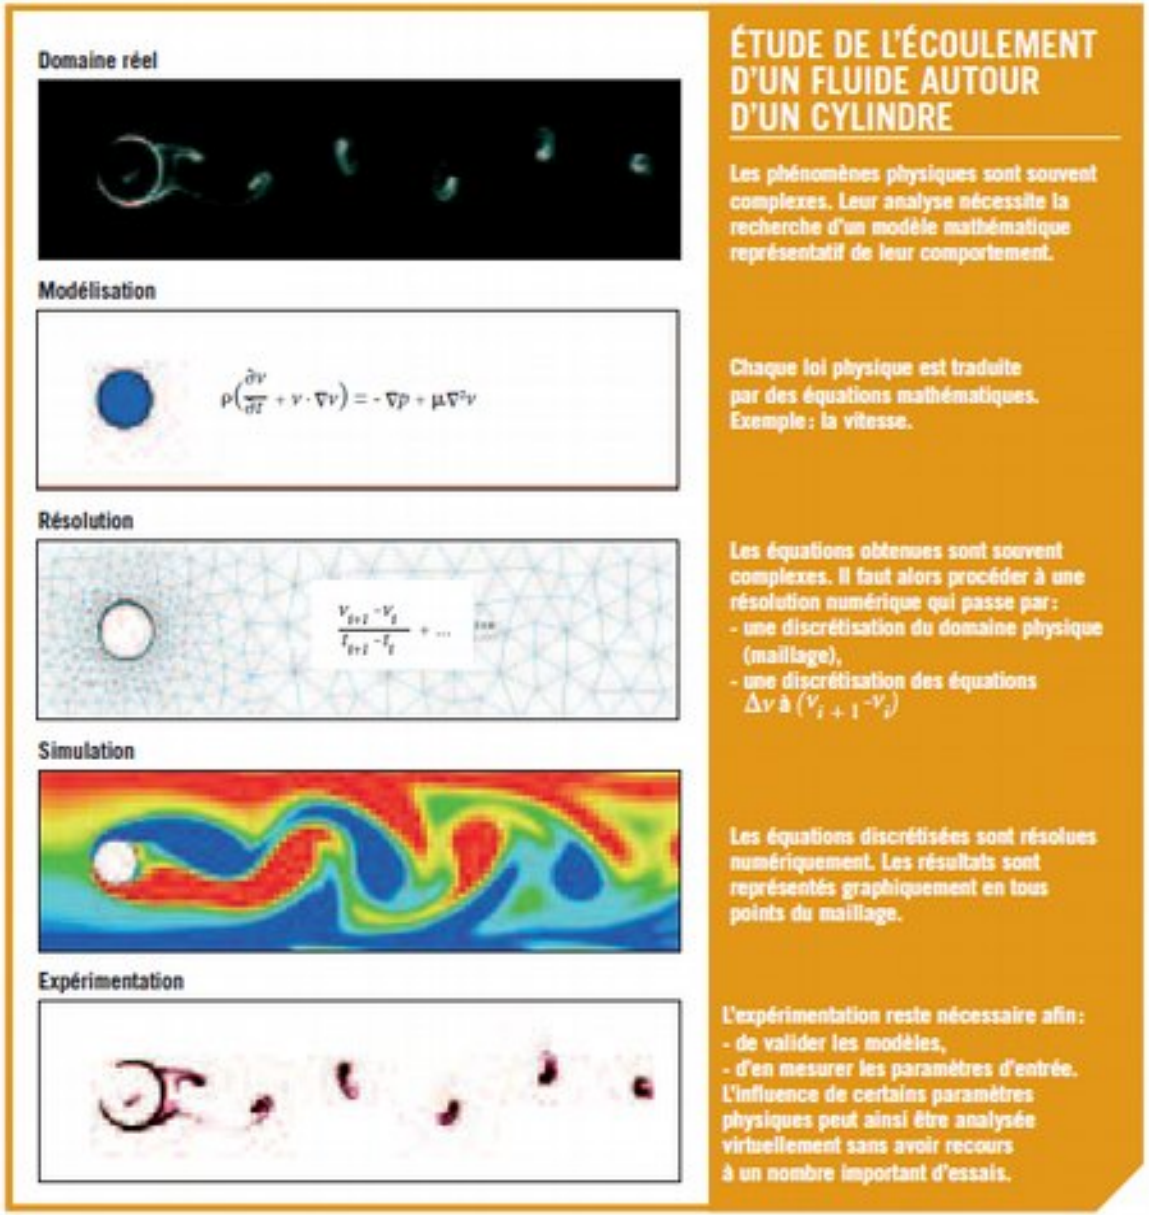

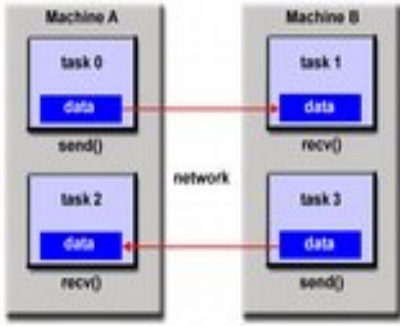

Le calcul parallèle

- Majoritairement dominé par le standard MPI (Message Passing Interface)
  - chaque tâche dispose de son propre espace mémoire
  - chaque tâche dialogue avec les autres tâches par transfert de messages
    - Différents type de messages (barrières, scatter/gather, broadcast, ...)
  - Souvent une tâche par cœur de calcul
    - Ou plusieurs si la tâche dispose de plusieurs threads de calcul
    - Donc plusieurs tâches sur un même nœud

- Mode Hybride MPI/OpenMP
  - OpenMP simplifie l'utilisation de plusieurs threads par tâche pour répartir les calculs des boucles de traitement type for / while (via pragma dans le code)

- Types de calcul parallèle
  - SPMD : Single Program Multiple Data
    - Chaque tâche exécute le même programme
  - MPMD : Multiple Program Multiple Data
    - Chaque tâche peut exécuter un programme différent

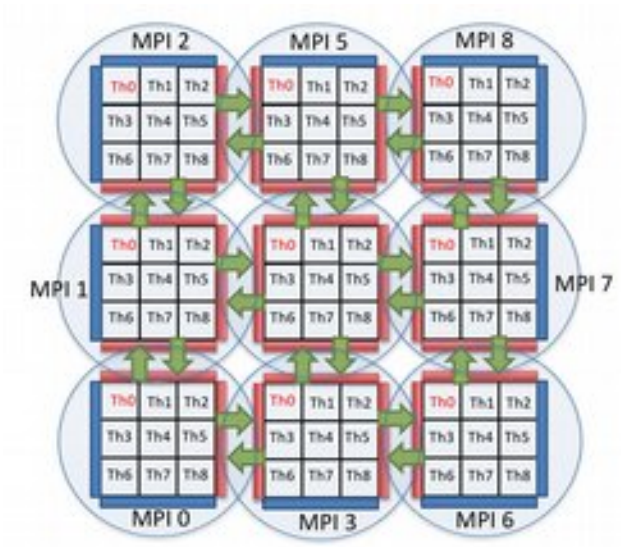

Présentation d’un centre de calcul

- Architecture

- Fonctionnement

Le centre de calcul

Supercalculateur

Stockage de données

Climatisation, refroidissement

Ligne électrique

Réseau haut débit

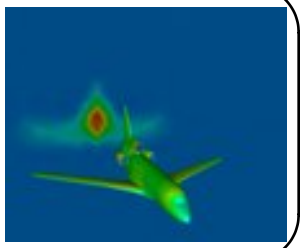

Des équipes d'experts pluridisciplinaires
pour piloter ces moyens exceptionnels et accompagner les utilisateurs

Architecture logique d'un centre de calcul

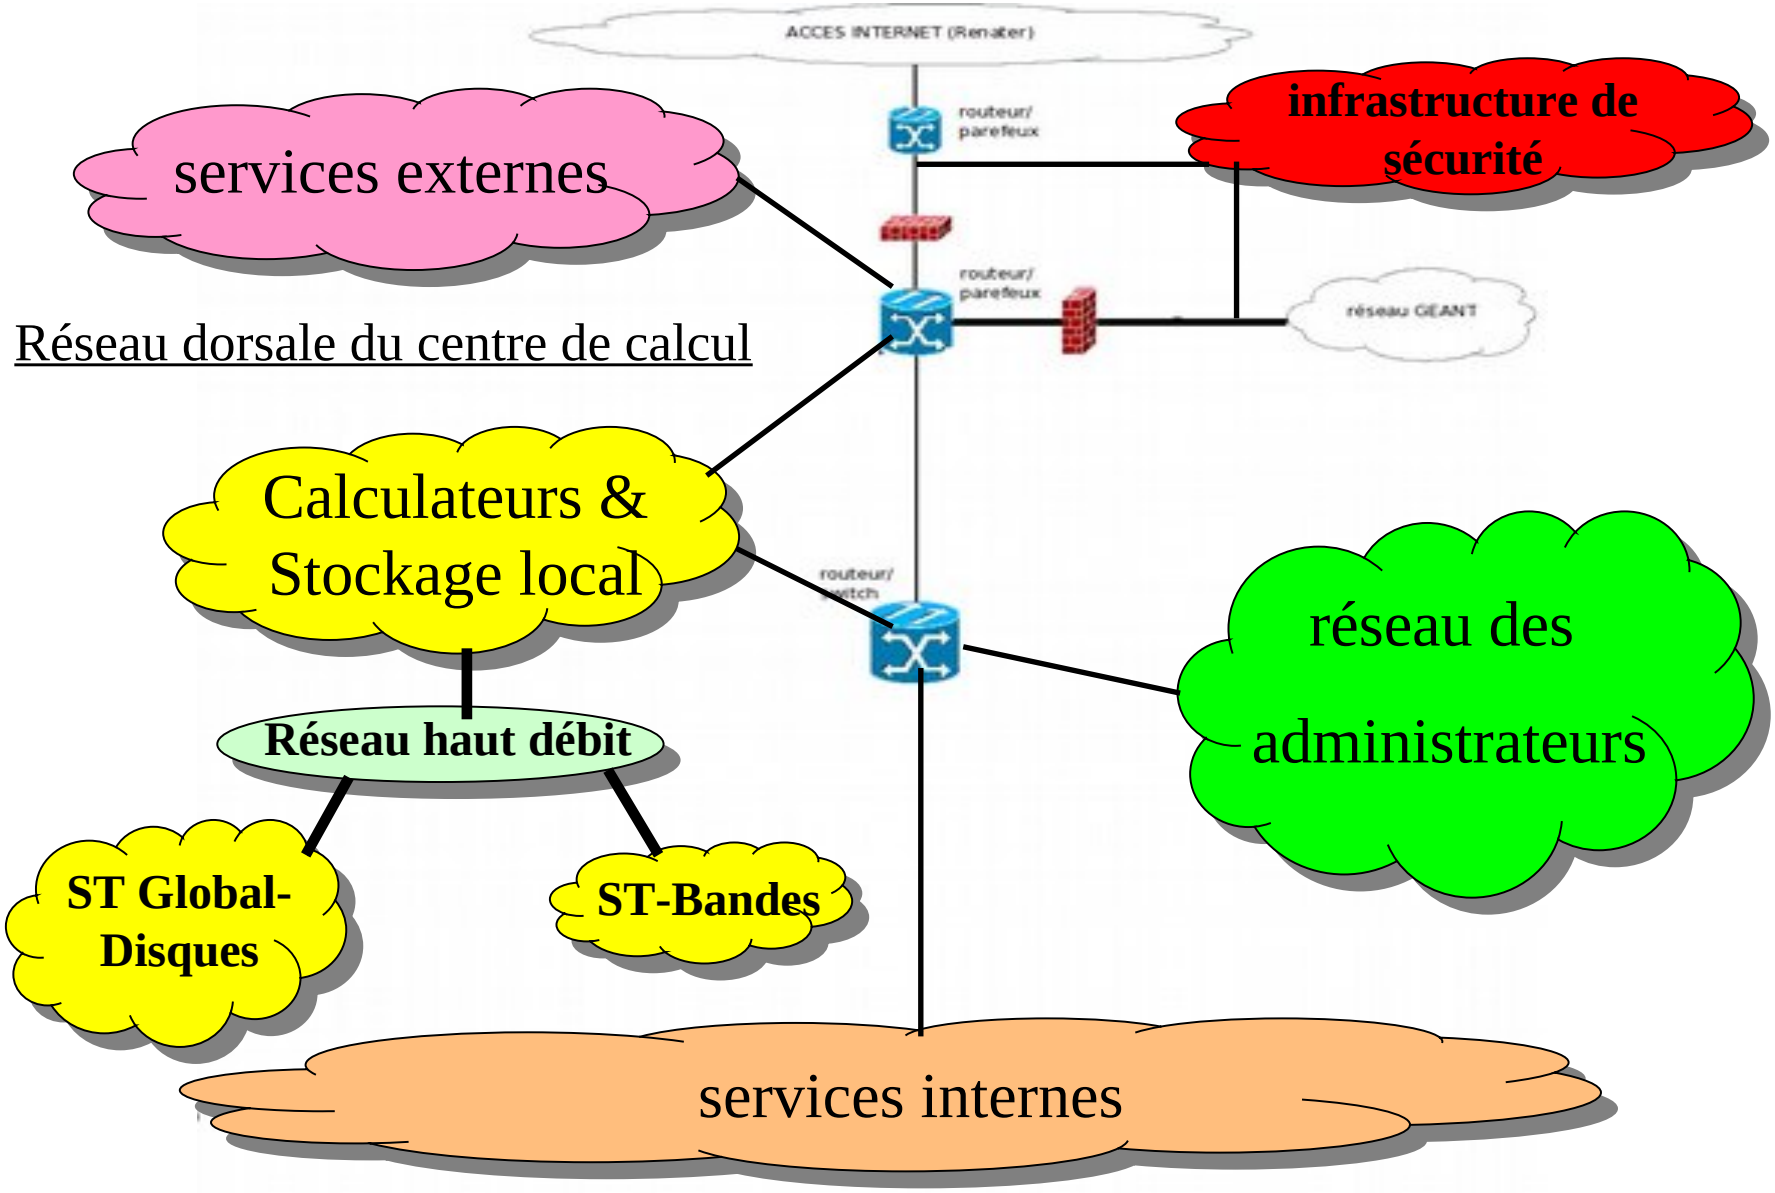

Les différents éléments

- Super-calculateurs
- Stockage
  - Home utilisateur
  - Stockage de résultats intermédiaires (intégré aux super-calculateurs)
  - Stockage des résultats définitifs
  - Archivage
- Clusters de pré/post traitement
- Autres
  - Clusters de statistiques

Le centre de calcul (les services)

- Services
  - Services « internes »
    - Authentification (LDAP, Kerberos, ...)
    - Identification (LDAP, ...)
    - DNS
    - Temps
    - Sauvegarde
    - Monitoring
    - Licences
    - ...
  - Services « externes »
    - Serveur web
    - Serveur de transfert
    - Serveur de soumission, de visualisation distante
    - ...
  - Services « administrateurs »
    - Outils de diffusion d'information (wiki), de communication (tchat)
    - Outils de gestion de configuration (puppet/ansible)
    - Outils de gestion de version (git), de bugs, de suivi de projets (YouTrack)
    - ...

Le centre de calcul (la sécurité)

La sécurité

- Sécurité périmétrique
  Sécurisation des points d'entrée/sorties du centre de calcul

- Sécurité en profondeur
  - Isolation / Bulles
  - Séparation entre les administrateurs et les utilisateurs
  - Protection des services administrateurs

  Rem :
  La sécurité de l'ensemble du centre de calcul dépend de la sécurité du plus faible élément

- Capacité d'analyse / forensics
  - Centralisation / analyses des logs
  - Stockage des logs « hors centre de calcul »
  - ...

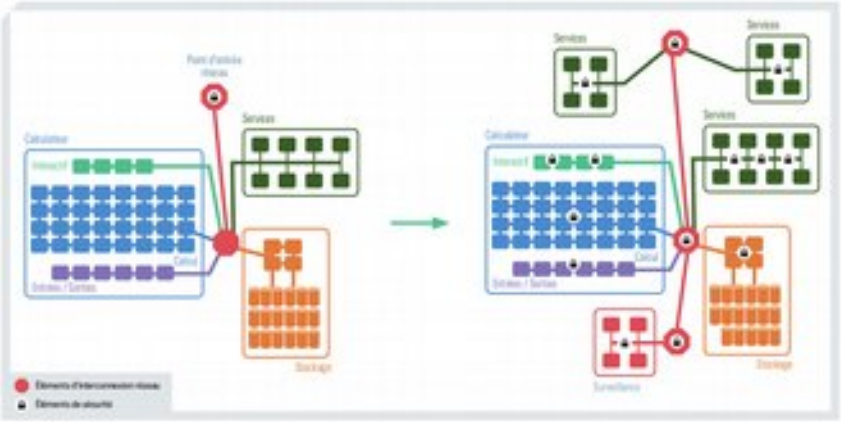

FIGURE 1
Passage de la sécurisation périmétrique à une sécurisation en profondeur du centre de calcul.

Les différents types d'architecture

- Standard
  - Les super-calculateurs possèdent leur propre stockage
- Data-centrique
  - Les ressources de stockage sont centralisés
- Hybride

Rem :

Cela dépend de l'utilisation du centre de calcul

Exemple d'architecture hybride

Principe

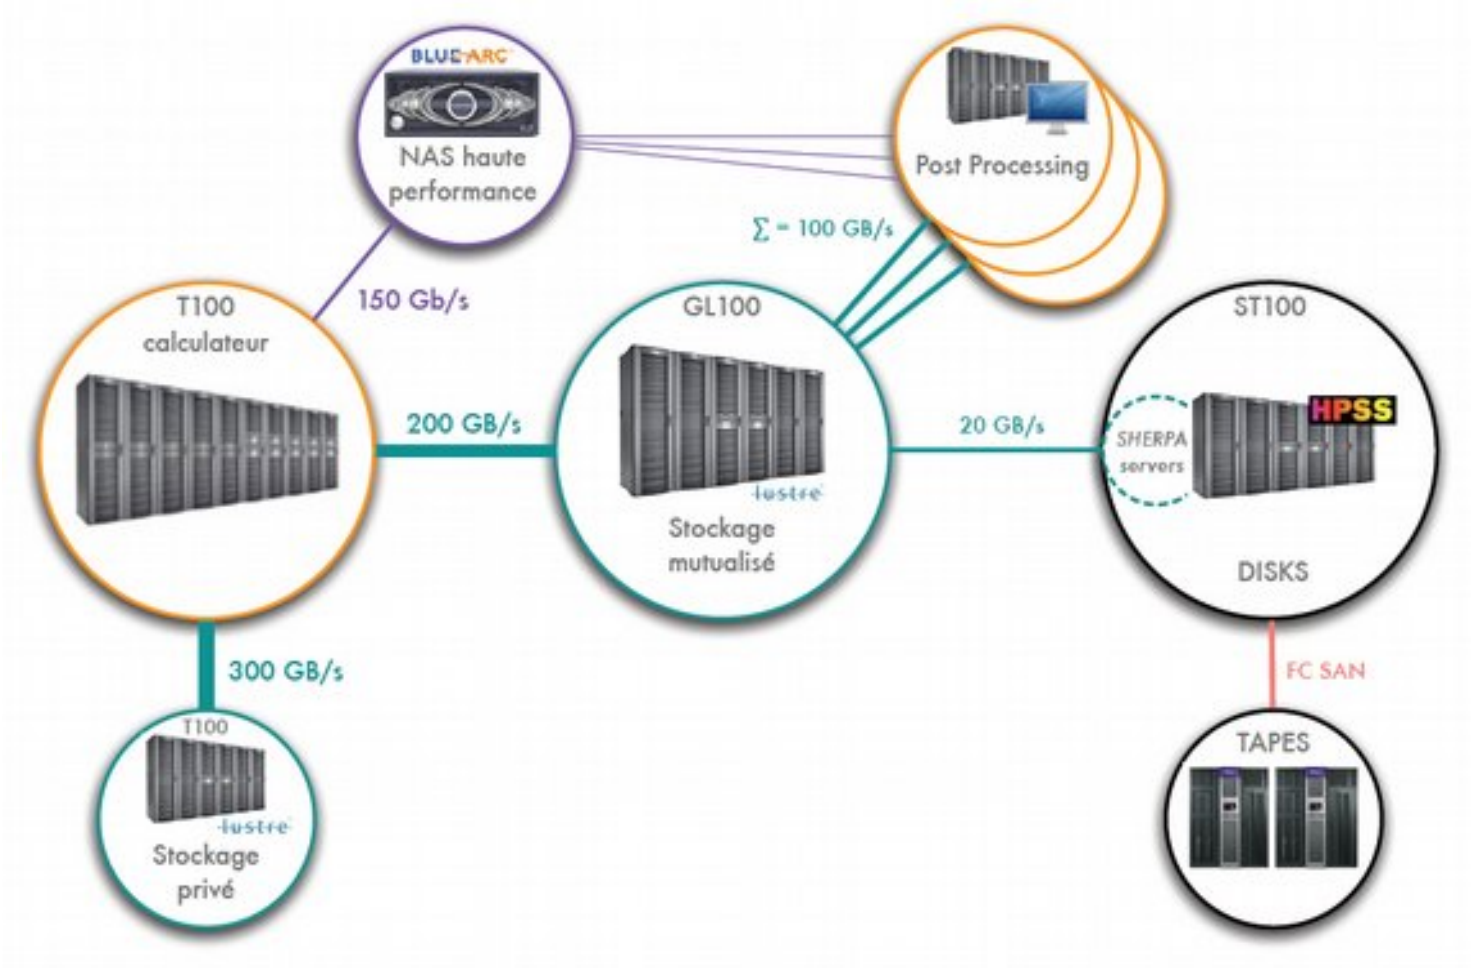

Le fonctionnement d’un centre de calcul

Le fonctionnement d'un centre de calcul

Calculateurs

Cluster de statistiques

Ordonnanceur

surveillance

Demandes utilisateurs

Stockage

Serveurs

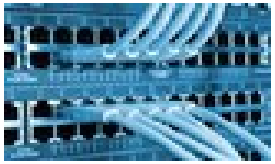

Réseau

Électricité

Refroidissement

Composantes principales d'un super-calculateur

Composantes principales d'un super-calculateur

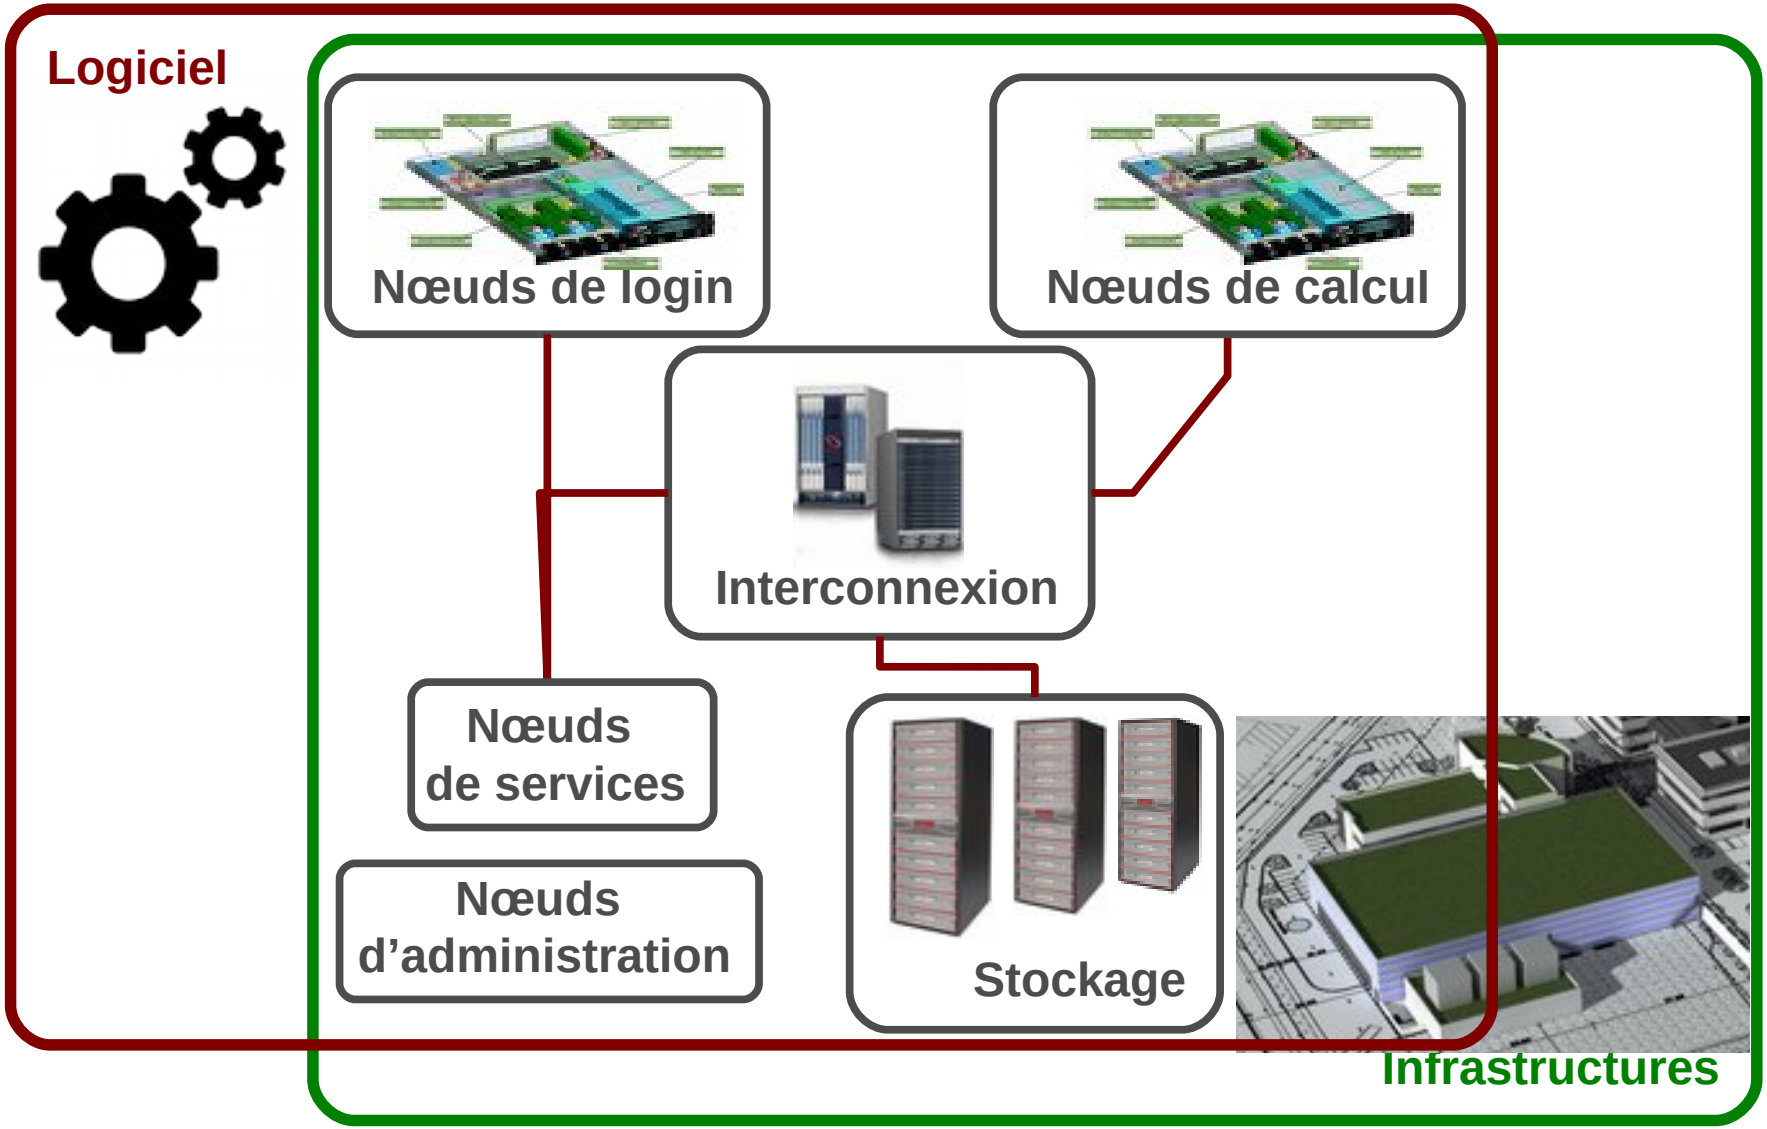

Les nœuds d’un super-calculateur

Différents types de nœuds

- Les nœuds de calcul
  - En grand nombre
  - Affectés aux travaux des utilisateurs
- Les nœuds de login
  - Point d'accès au calculateur
  - Nécessaire à la compilation, au déverminage, au travail préparatoire
  - Généralement même architecture que la partition de calcul
- Les autres nœuds
  - Les nœuds de visualisation :
    - solution de visualisation des résultats
    - Bureau virtuel optimisé
  - Les nœuds « grosse mémoire »
    - nécessaire pour le pré/post traitement, maillage, etc..
- Les nœuds de services
  (utile pour faire tourner des process de soumission, ...)
- Les nœuds d'administration

Objectifs

Nœuds de calcul

- Fournir la puissance de calcul unitaire du système
  - Architecture multi-processeurs, multi-cœurs
    - Majoritairement NUMA (Non-Uniform Memory Access)
- Fournir le volume mémoire nécessaire à la résolution des problèmes
  - Ainsi que des débits mémoires optimums
- Fournir les accès aux réseaux de communication du calculateurs
  - Réseaux d'administration et de gestion
  - Réseaux rapides de calcul/stockage
- Minimiser l'espace/volume nécessaire
  - Pour maximiser le nombre de serveurs sur une même empreinte au sol
- Garantir un fonctionnement constant et optimal

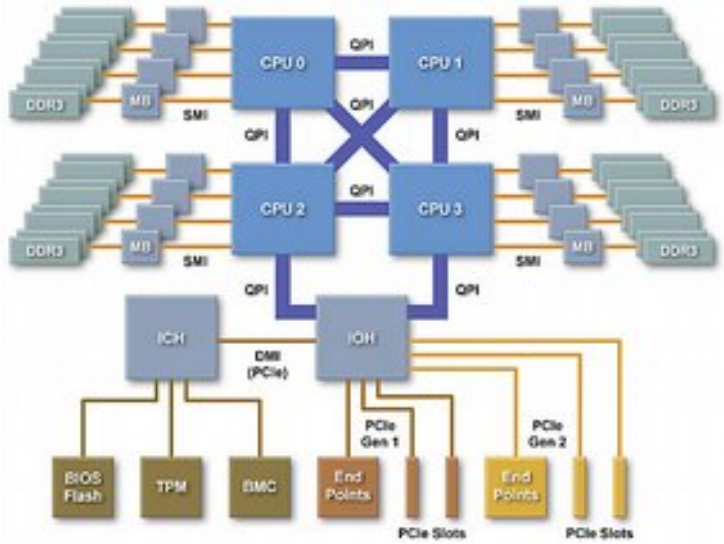

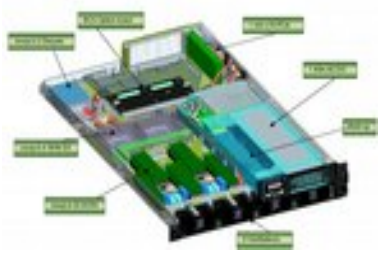

Nœuds de calcul

Processeurs

- Majoritairement scalaire de type x86 64 bit (SISD)
  - Multi-cœurs
  - Instructions vectorielles (AVX, type SIMD)
    - Intéressant pour certains types de calcul
- Intel historiquement bien implanté sur le marché
  - KNL, Skylake (2017, 14nm, 28c), CascadeLake(2019, 14nm, 32c), CooperLake (2020, 14nm, 28c), IceLake (2021, 10nm, 40c), Sapphire Rapids (10nm)
  - En retard sur les procéssus de gravure
- AMD : epyc/zen : Rome (2019, 7nm, 64c), Milan (2020, 7nm, 64c)
- GPU : Nvidia V100, A100 - AMD Instinct MI100
- ARM : Fuji, Apple, Microsoft ?
- EPI (European Processor Initiative) in 2023 ?
  - https://www.european-processor-initiative.eu/

Taxonomie de Flynn

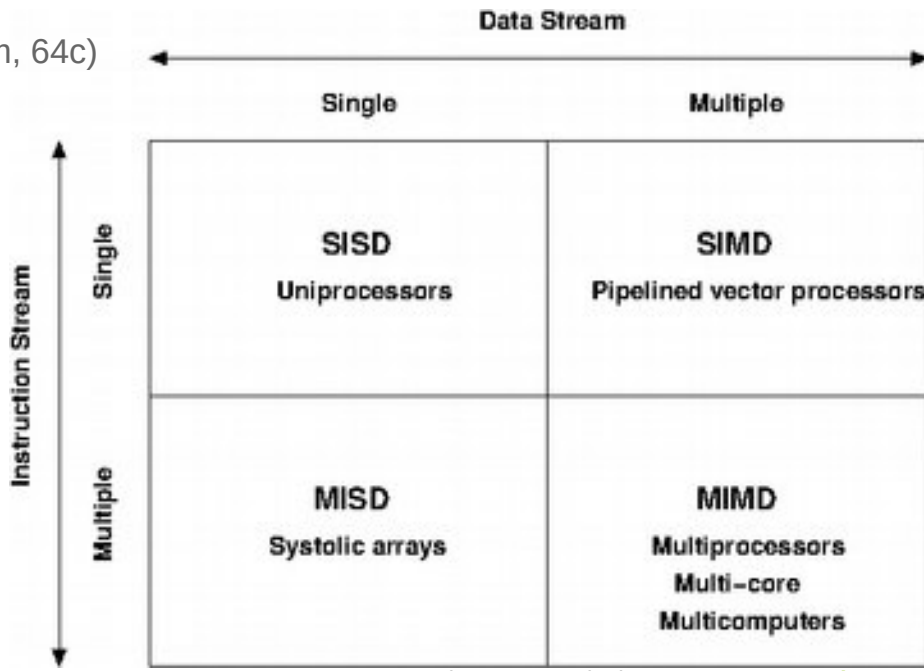

Roadmap AMD

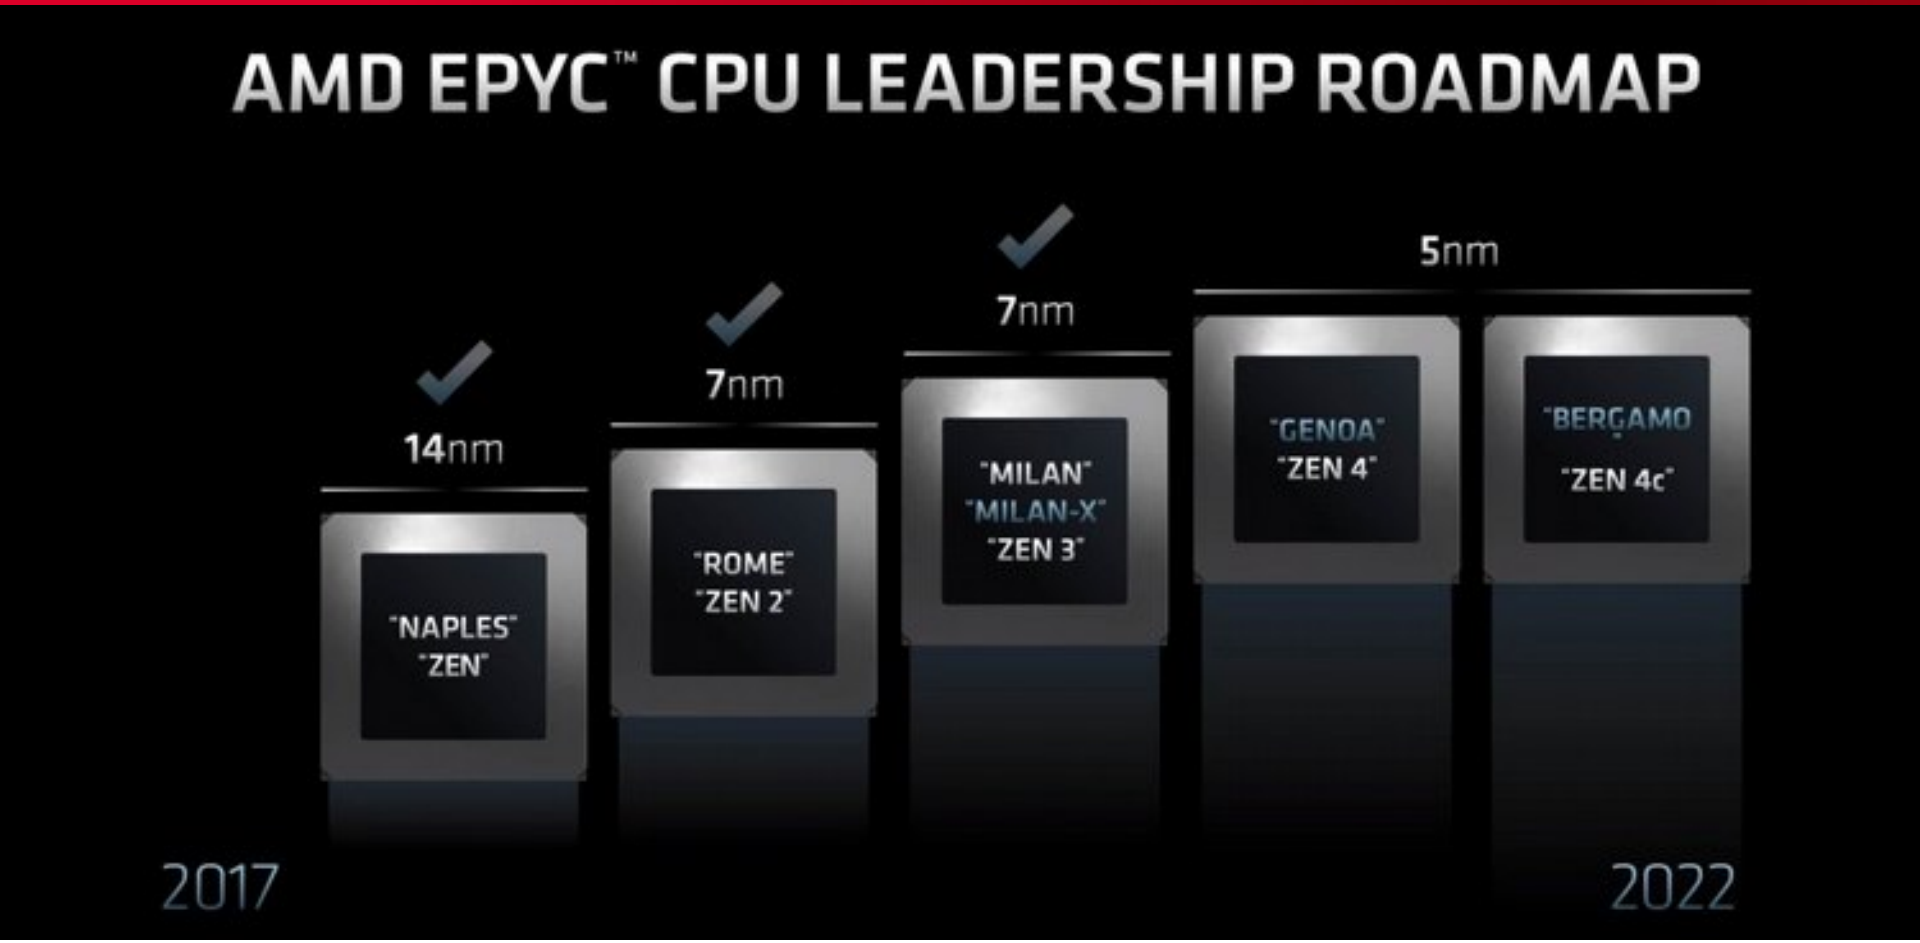
AMD EPYC™ CPU LEADERSHIP ROADMAP
14nm
"NAPLES"
"ZEN"
7nm
"ROME"
"ZEN 2"
7nm
"MILAN"
"MILAN-X"
"ZEN 3"
5nm
"GENOA"
"ZEN 4"
"BERGAMO
"ZEN 4c"
2017
2022

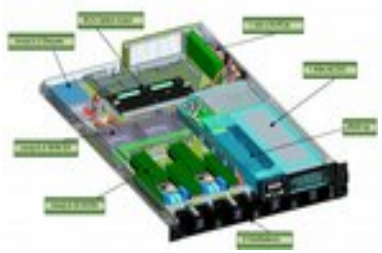

Nœuds de calcul

Accélérateurs HW

- Utilisation croissante d'accélérateurs additionnels
  - GPU type NVIDIA
  - Many-core type Intel MIC (KNL)
- Nécessite une adaptation/modification des codes
  - Travail potentiellement conséquent
- Gains relatifs aux types d'application
  - Bus de communication PCI limite les débits mémoire centrale <-> mémoire accélérateur
  - Nécessite une grande autonomie des calculs une fois chargés sur accélérateur

Composantes principales d'un super-calculateur
Les nœuds de calcul : un processeur AMD

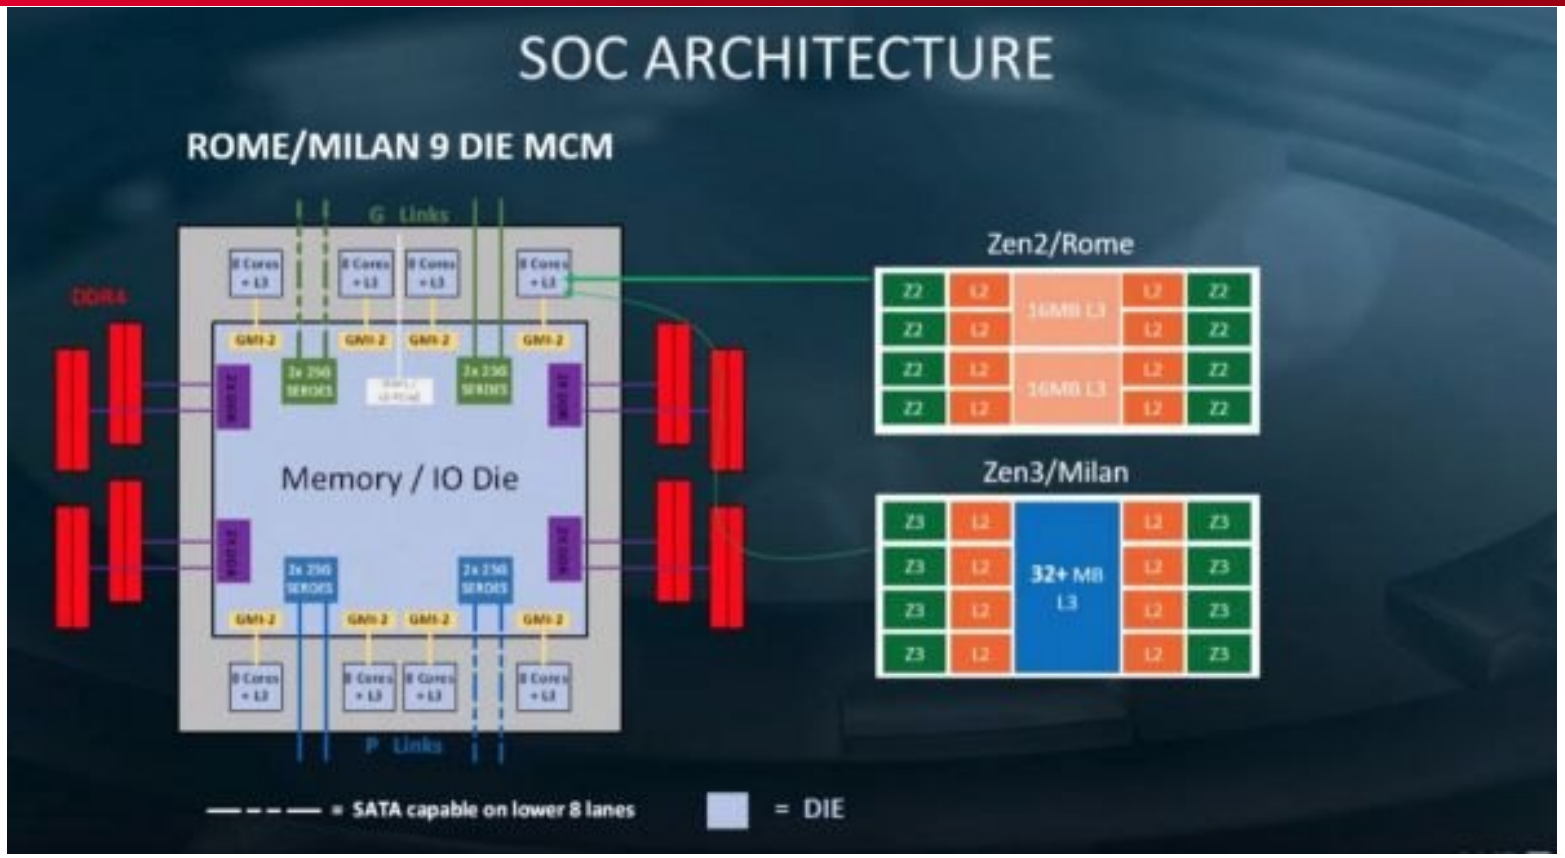

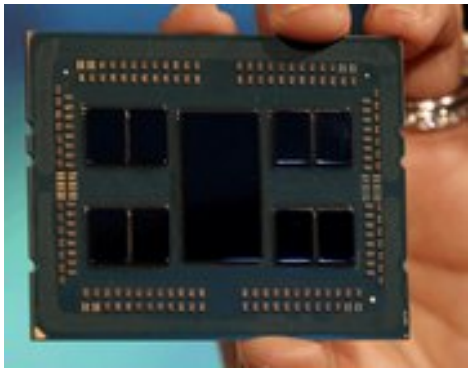

Composantes principales d'un super-calculateur
Les nœuds de calcul GPU ou CPU ?

AMD EPYC 7002 SERIES PROCESSOR DETAILS

Model	Cores	Threads	Base Freq. (GHz)	Max. Boost Freq. (GHz)*	TDP (W)	L3 Cache (MB)	DDR Channels	Max DDR Freq. (1DPC)	Per Socket Theoretical Memory Bandwidth (GB/s)	PCIe® Gen 4 Lanes	2P/1P
7H12	64	128	2.6	3.3	280	256	8	3200	204.8	128	2P/1P
7742	64	128	2.25	3.40	225	256	8	3200	204.8	128	2P/1P
7702	64	128	2.00	3.35	200	256	8	3200	204.8	128	2P/1P
7702P											1P only
7642	64	128	2.00	3.30	225	256	8	3200	204.8	128	2P/1P
7642	48	96	2.30	3.30	225	256	8	3200	204.8	128	2P/1P
7552	48	96	2.20	3.30	200	192	8	3200	204.8	128	2P/1P
7542	32	64	2.90	3.40	225	128	8	3200	204.8	128	2P/1P
7532	32	64	2.40	3.30	200	256	8	3200	204.8	128	1P/1P
7502	32	64	2.50	3.35	180	128	8	3200	204.8	128	2P/1P
7502P											1P only
7452	32	64	2.35	3.35	155	128	8	3200	204.8	128	2P/1P
7F72	24	48	3.2	3.7	240	192	8	3200	204.8	128	2P/1P
7402	24	48	2.80	3.35	180	128	8	3200	204.8	128	2P/1P
7402P											1P only
7352	24	48	2.30	3.20	155	128	8	3200	204.8	128	2P/1P
7F52	16	32	3.5	3.9	240	256	8	3200	204.8	128	2P/1P
7302	16	32	3.00	3.30	155	128	8	3200	204.8	128	2P/1P
7302P											1P only
7282	16	32	2.80	3.20	120	64	8	3200	85.3	128	2P/1P
7272	12	24	2.90	3.20	120	64	8	3200	85.3	128	2P/1P
7F32	8	16	3.70	3.90	180	128	8	3200	204.8	128	2P/1P
7262	8	16	3.20	3.40	155	128	8	3200	204.8	128	2P/1P
7252	8	16	3.10	3.20	120	64	8	3200	85.3	128	2P/1P
7232P	8	16	3.10	3.20	120	32	8	3200	85.3	128	1P only

NVIDIA GPU 100 SPECS

SYSTEM SPECIFICATIONS (PEAK PERFORMANCE)

	4-GPU	8-GPU	16-GPU
GPUs	4x NVIDIA A100	8x NVIDIA A100	16x NVIDIA A100
HPC and AI Compute FP64/ TF32*/FP16*/ INT8*	78TF/1.25PF*/ 2.5PF*/5POPS*	156TF/2.5PF*/ 5PF*/10POPS*	312TF/5PF*/ 10PF*/20POPS*
Memory	160 GB	320 GB	640 GB
NVIDIA NVLink	3rd generation	3rd generation	3rd generation
NVIDIA NVSwitch	N/A	2nd generation	2nd generation
GPU-to-GPU Bandwidth	600 GB/s	600 GB/s	600 GB/s
Total Aggregate Bandwidth	2.4 TB/s	4.8 TB/s	9.6 TB/s

* With sparsity

Composantes principales d'un super-calculateur
Lame de calcul SEQUANA des machines T1000

- Blade view with 3 KNL nodes (1S)
- Interconnect NIC on mezzanine to uncorrelate CPU and BXI/IB
- PCIe switch to share 3 PCIe disks among nodes
- Motherboard : CKL (Compute KnL board)

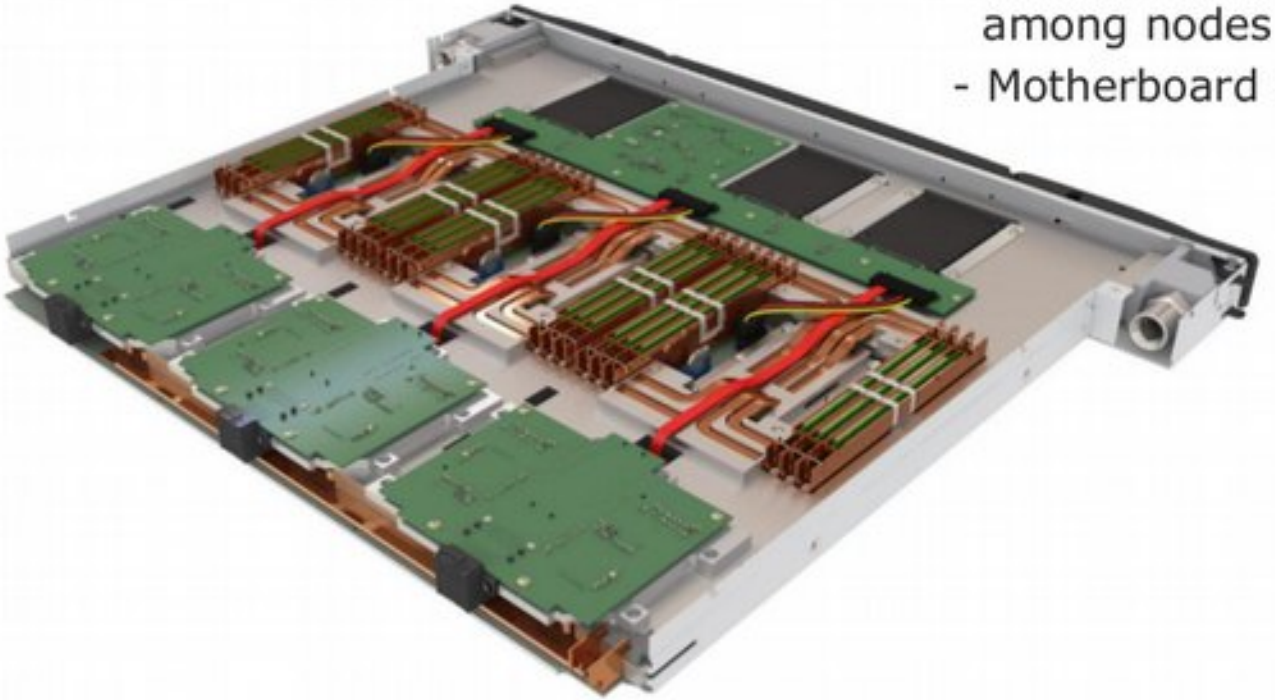

Composantes principales d'un super-calculateur
Rack Sequana2 Atos Bull

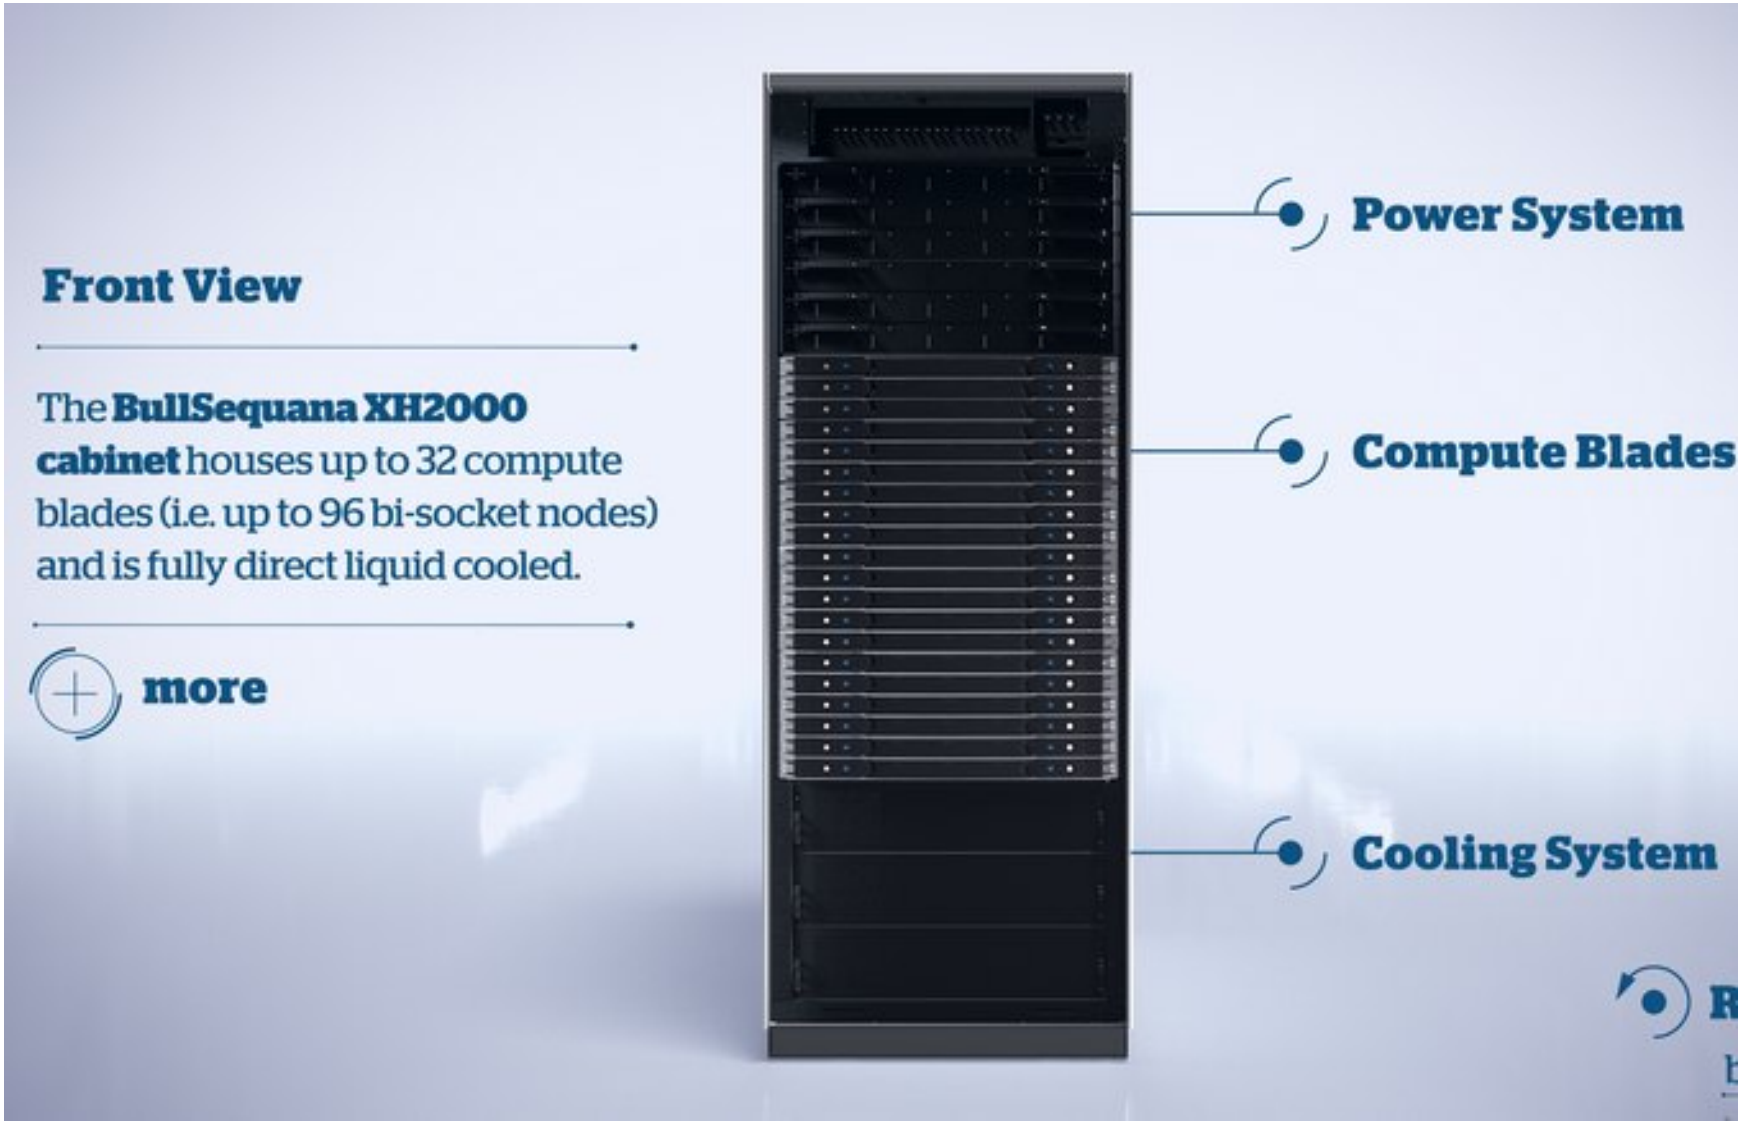

Composantes principales d'un super-calculateur
Rack Sequana 2 Atos Bull

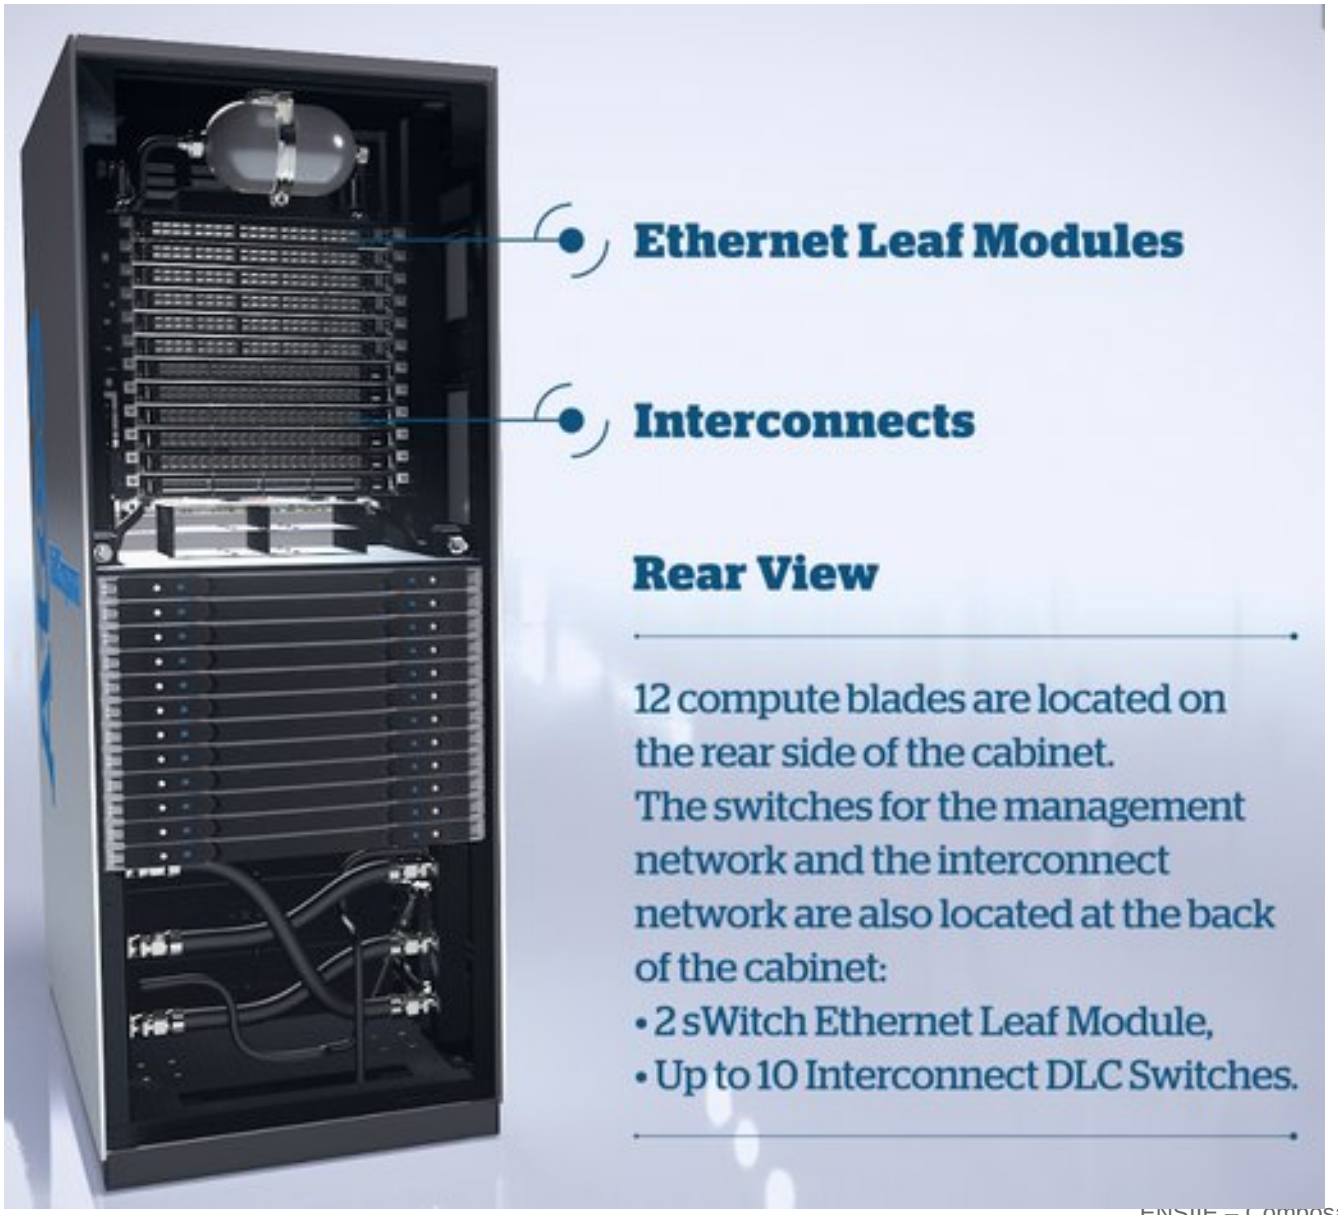

Le réseau d’interconnexion

Interconnexion

Objectifs

- Fédérer l'ensemble des entités de calcul et de stockage
  - Fournir l'ensemble des connexions point à point entre tous ces composants
- Fournir une très bonne qualité de service aux applications et aux systèmes de fichiers distribués
  - En terme de bande passante (débit)
  - En terme de latence
- Assurer la tolérance aux pannes des équipements d'interconnexion
  - Dans la limite de la conservation de la connectivité
  - En dégradant le service par une diminution des débits (congestion plus forte)

Réseau d'interconnexion

- Peut être couplé/lié à l'architecture du proces
- Différents types
  - Propriétaires
    - **IBM : --**
    - **Cray : Aries, Slingshot**
    - Fujitsu : Tofu
    - Atos : BXI
    - ~~Intel : OmniPath~~
  - Standardisés
    - **Infiniband**
    - 1/10:100Gb Ethernet

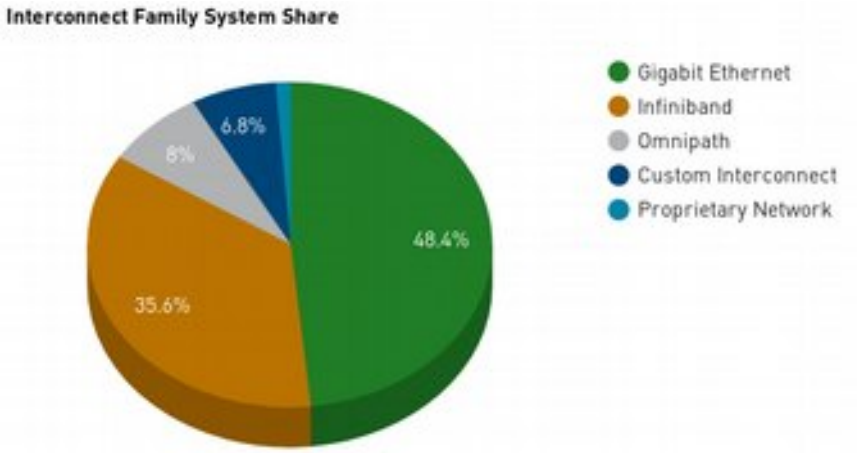

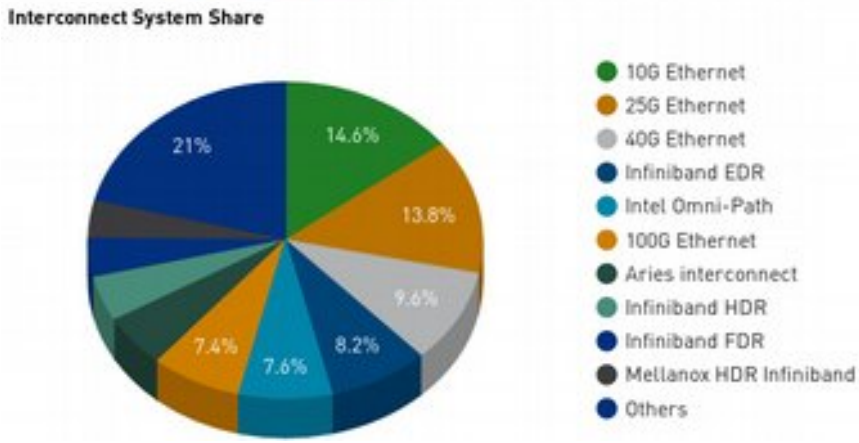

Réseau d'interconnexion

- Différentes caractéristiques
  - Latences : de l'ordre de la **µs** à quelques ms
  - Débits : 1Gb/s, 10 Gb/S, **40 Gb/s, 54 Gb/s, 100 Gb/s, 200Gb/s ...**
  - Packet-switched / Circuit-Switched (transfert de paquets ou établissement d'un circuit)
  - Bloquant / Non-bloquant (il existe toujours un chemin possible entre 2 nœuds)
  - Arité : nombre de ports par switchs
  - Disponibilité de gros switchs (switchs director)
  - Topologie supportée
  - Capacités : **RDMA (Remote Direct Memory Access)**,
  - Gestion de la congestion : Routage adaptatif, ...

Interconnexion

Topologie d'interconnexion

- Détermine la manière dont les nœuds sont fédérés
  - Les différents niveaux de regroupement
  - Les connexions entre regroupements
- Détermine les caractéristiques du réseau
  - Nombre de nœuds maximum
  - Nombre de sauts maximum entre deux nœuds (diamètre)
  - Différents niveaux de localité (voisinages réseaux)
  - ...
- Topologies courantes

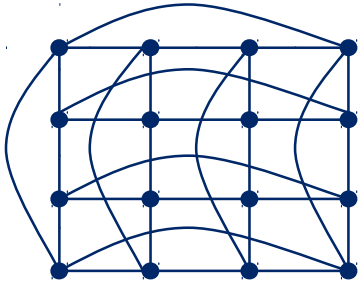

Tore 2D (3D, ...)

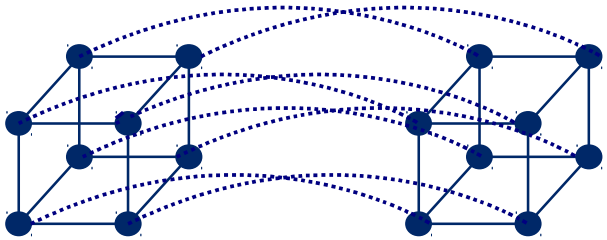

Hypercube

Arbre (Fat Tree)

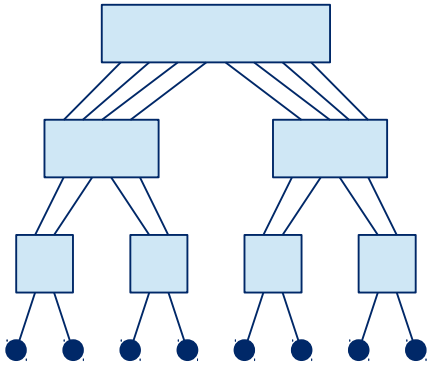

Interconnexion

Topologie d'interconnexion

Fat Tree
~4000 nœuds

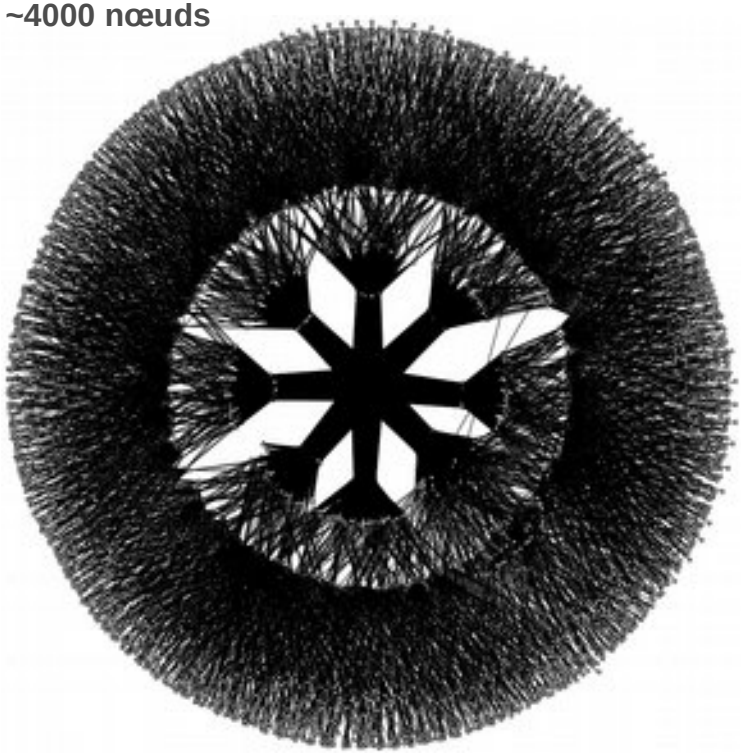

3D Torus
~8000 Nœuds

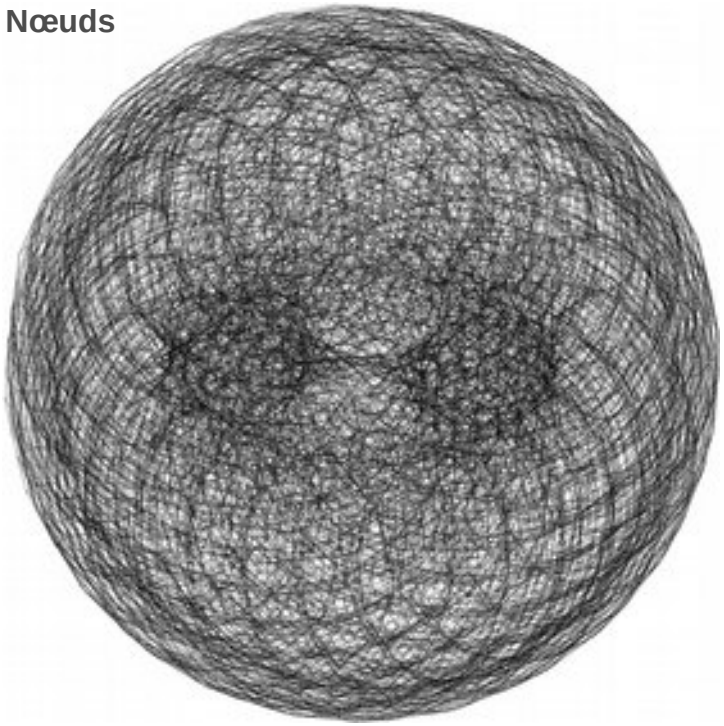

Gestion du réseau d'interconnexion

- Nécessité de gérer le réseau pour :
  - Définir des routes pour aller d'un nœud à un autre
  - Identifier les liens et nœuds en panne
    - Monitoring / alerte
    - Trouver des routes alternatives

=> Role du « fabric manager »

- 2 types de gestion :
  - In band :
    les trames de gestion du réseau se font sur le réseau lui-même
  - Out of band :
    les trames de gestion du réseau se font hors du réseau d'interconnexion (via en générale le réseau d'administration)

Le stockage

Objectifs

- Fournir un service de systèmes de fichiers distribués
  - Ex : NFS, GPFS, Lustre, ...
- Fournir les capacités de stockage nécessaires au bon déroulement des applications
  - Fonction du type d'applications exécutées et de leurs volumes produits
- Fournir les débits d'accès globaux attendus en lecture/écriture pour l'ensemble du calculateur
  - Plusieurs applications s'exécutent simultanément en production sur un calculateur
- Assurer la cohérence et la robustesse du service de stockage
  - Tolérance aux pannes matérielles courantes
- Assurer la conservation des données critiques sur de longues périodes de temps
  - Données coûteuses à générer nécessitant un archivage à long terme

Composantes principales d'un super-calculateur
Le stockage

Principe

- Utilisation de baies de disques à hautes performance & disponibilité
  - Exportant un ensemble de cibles disques SAN
    - Donc une certaine capacité à un certain débit
  - En assurant la robustesse du service
    - Contrôleurs SAN redondants et remplaçables à chaud
    - Disques remplaçables à chaud
    - Cibles configurées en RAID 5/6
      - Redundant Array of Independant Disk mode 5 ou 6 : Répartition des données sur plusieurs disques autorisant de 1 à plusieurs pannes de disque simultanées
  - Ex: baie DDN SFA10K
    - 300 disques 1TB -> 300 TB RAW
    - 30 LUN de 10 disques en RAID 6 (8+2)
    - Débit 10GB/s
- Agrégation de plusieurs baies
  - En fonction des capacités et débits globaux souhaités

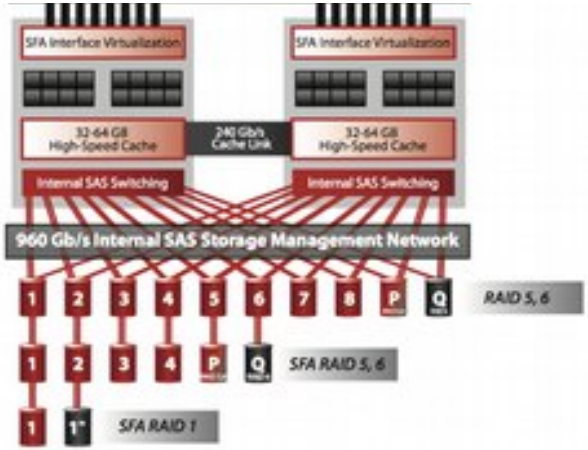

Principe

- Utilisation de nœuds de services intermédiaires
  - Accédant aux données des baies
  - Exportant les données aux nœuds de calcul
    - Nœuds « agents » des systèmes de fichiers distribués
    - Via le réseau d'interconnexion rapide
  - Agrégés par « cellule »
    - Ensemble de nœuds de service connectés aux même baies
    - Permettant une tolérance aux pannes à l'intérieur de la cellule
      - Perte d'un nœud tolérée
    - Permettant de fournir le débit des baies associées sur le réseau haute performance

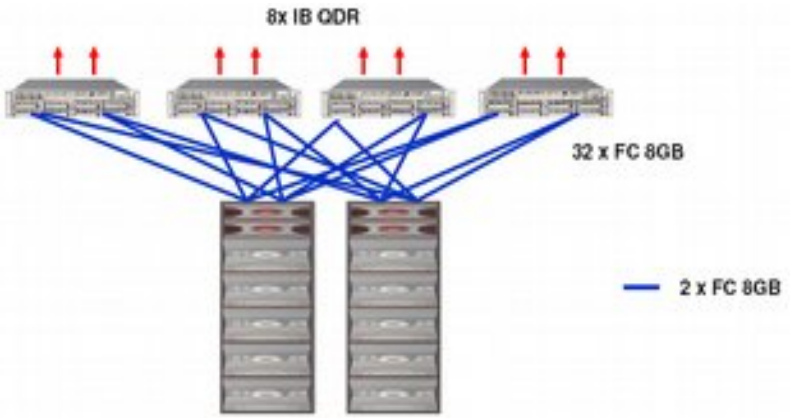

Réseau de stockage

- Plus ouvert que le réseau d'interconnexion du calculateur
- Fédère les calculateurs, autres clusters et clusters de stockage
- Technologie reposant sur des standards :
  - Infiniband
  - 100 Gb Ethernet

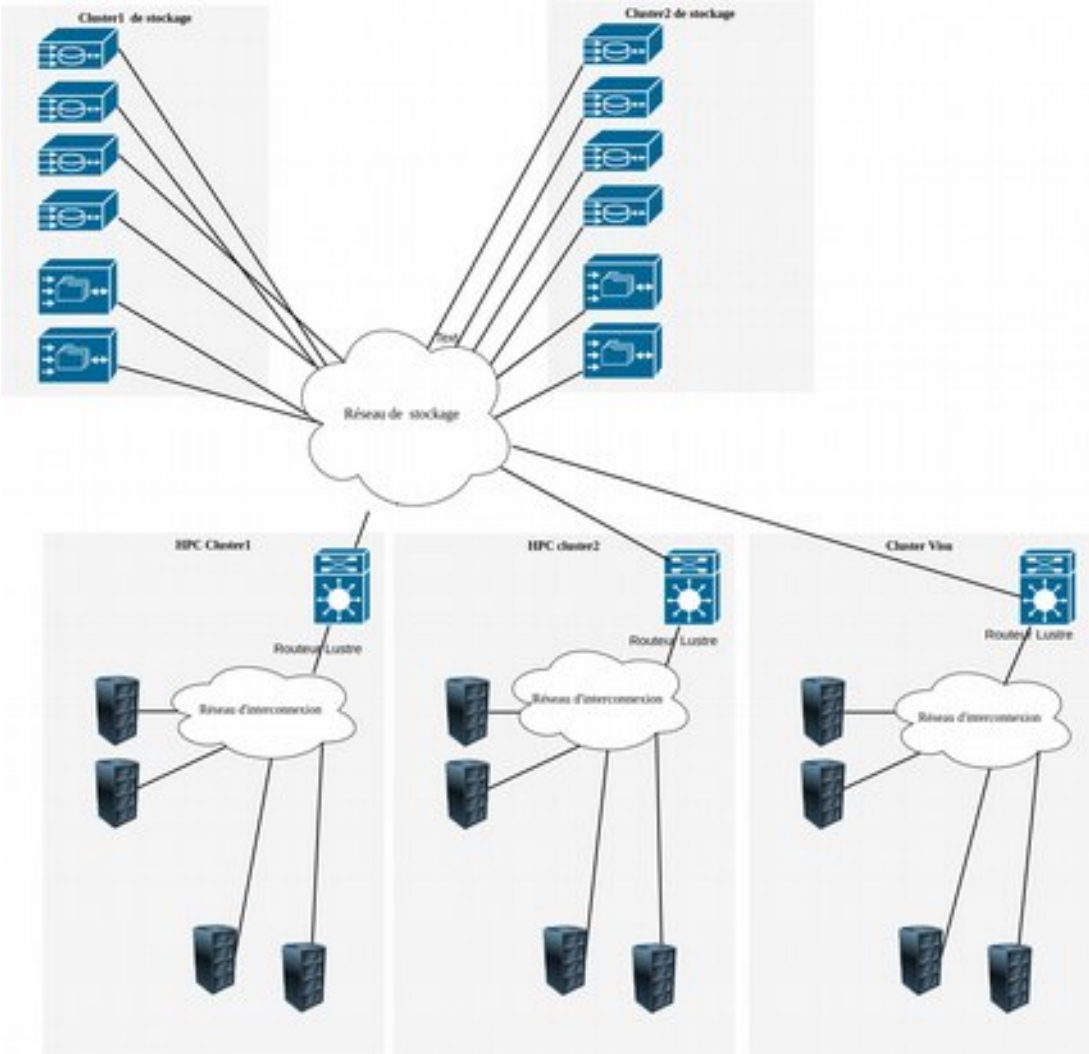

Principe

- Système de fichiers distribués parallèle
  - Différents types
    - **Lustre** (Intel), GPFS (IBM), GFS (RedHat), pNFS (EMC, NetApp, IBM)
    - Avec différentes caractéristiques (cohérence entre clients, gestion des locks,...)
  - Agrège l'ensemble des « cellules IO »
    - Ou une sous-partie
  - Propose un système de fichiers classique (POSIX)
    - « Montable » sur les nœuds de calcul

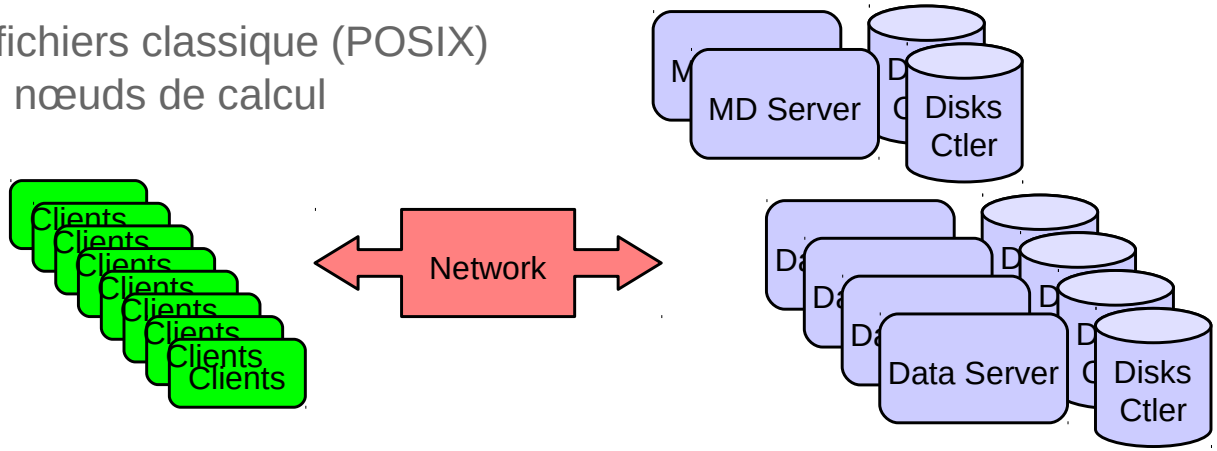

En résumé

Architecture simple

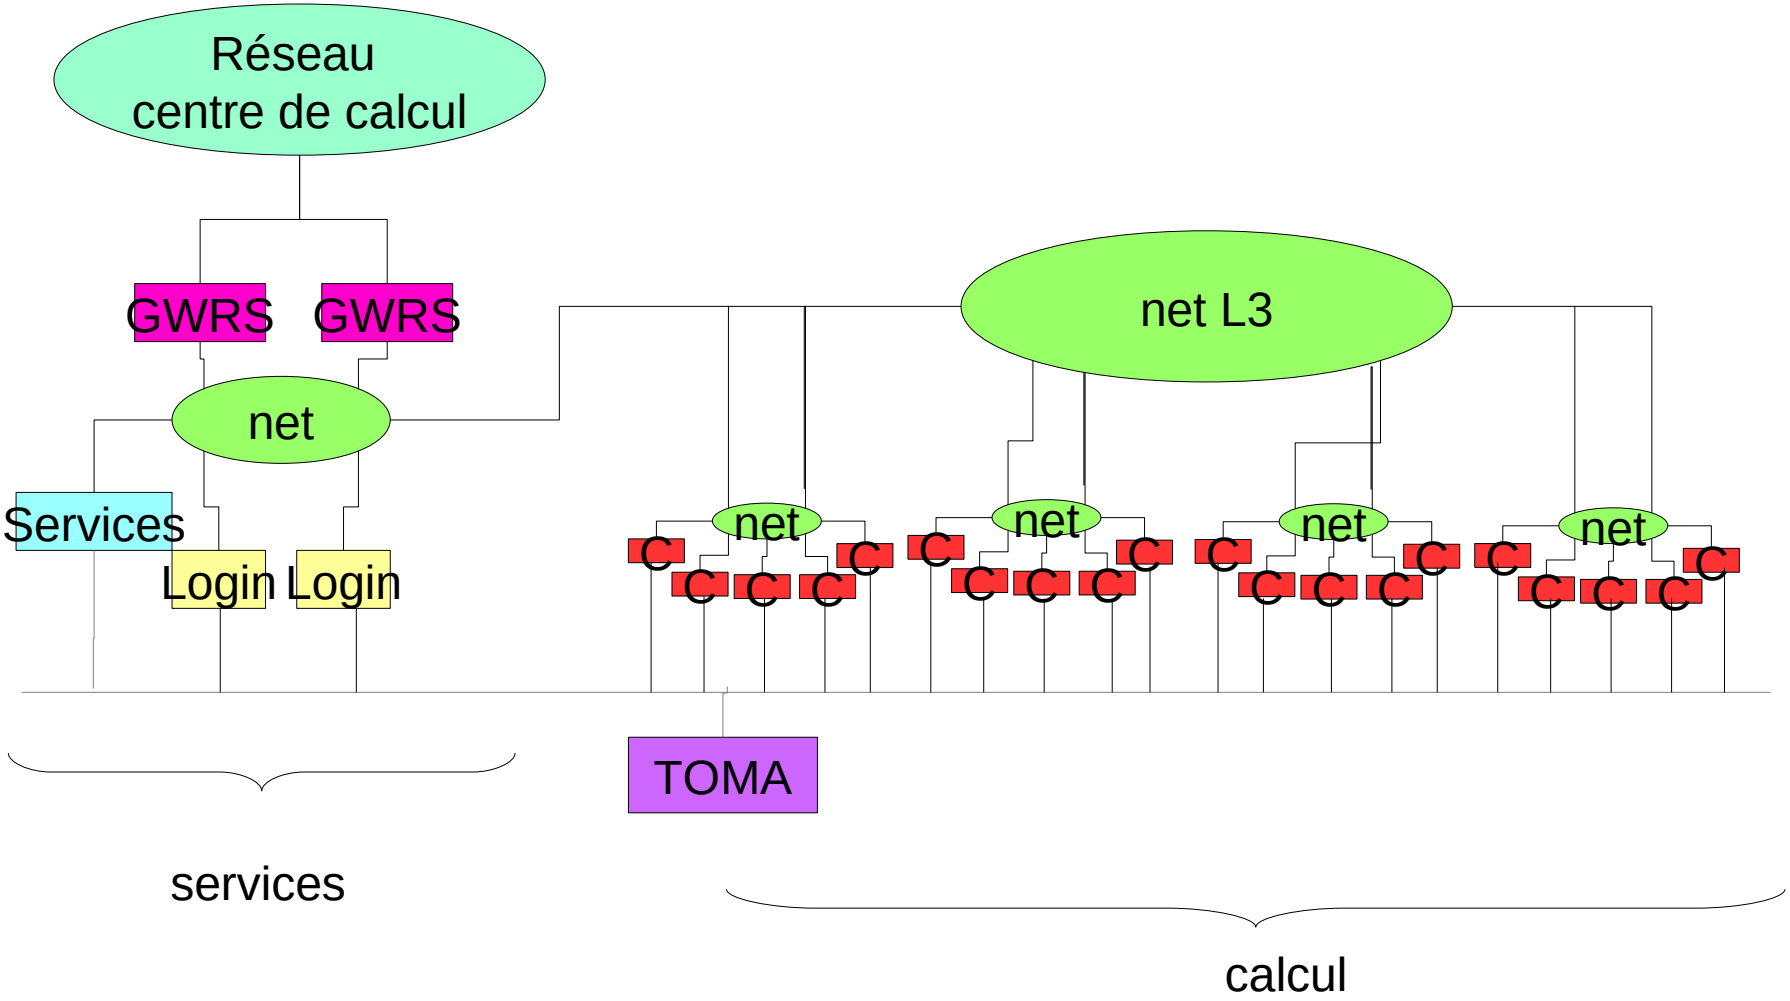

Architecture îlotée

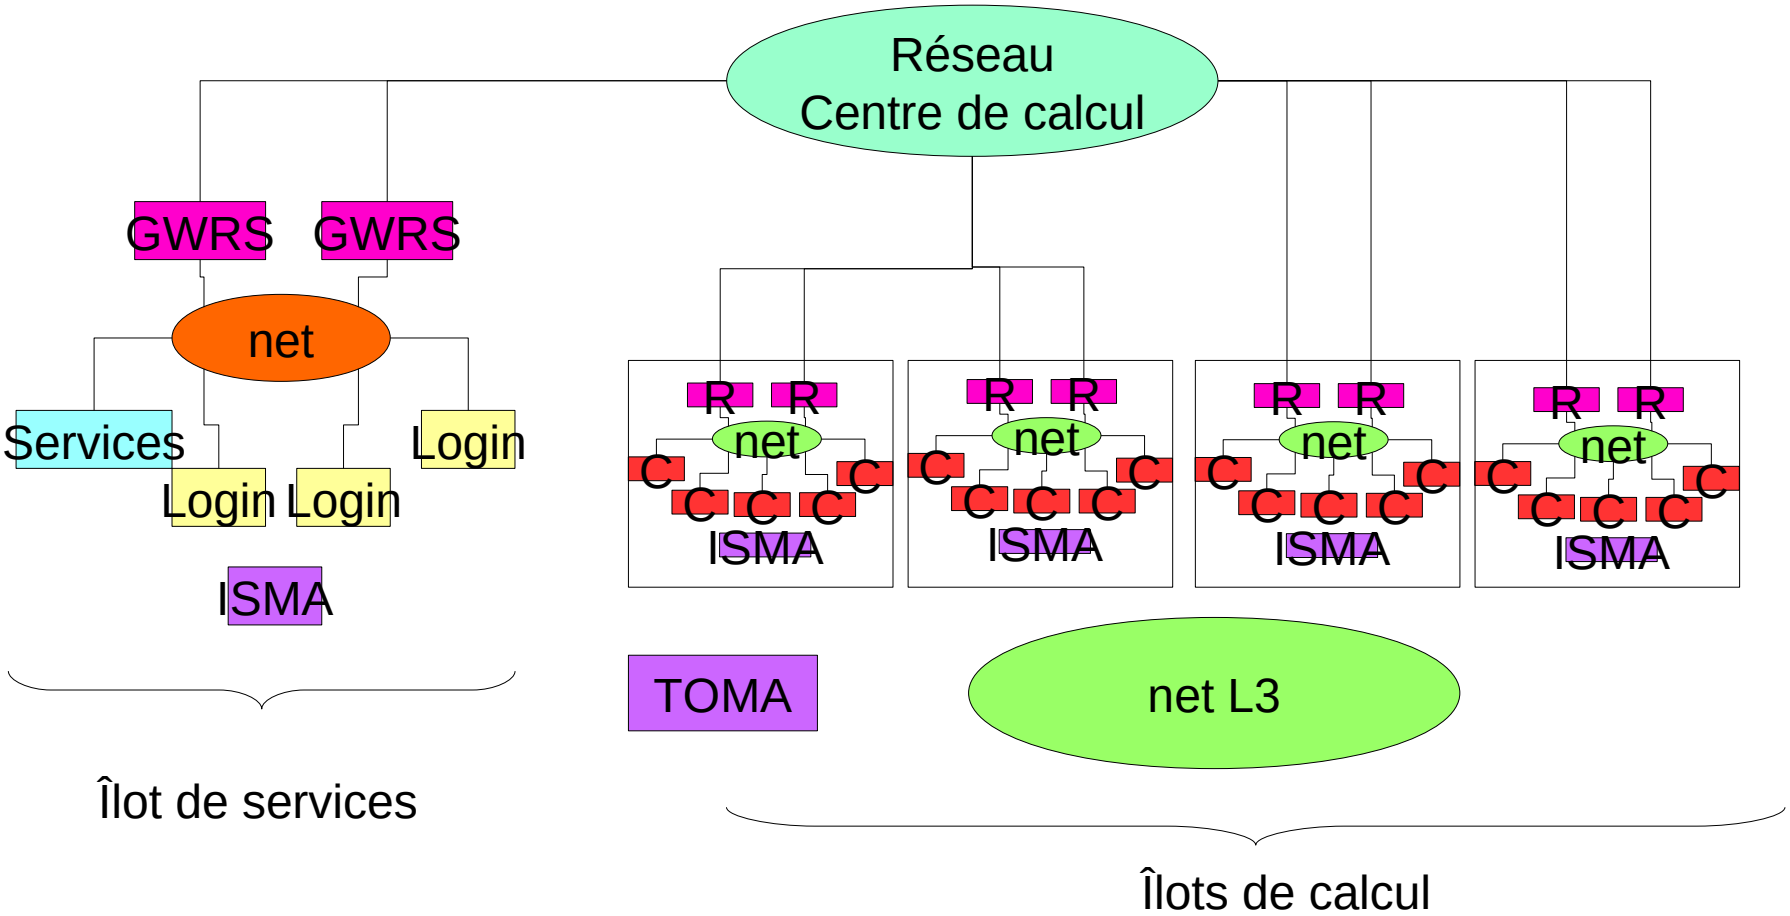

Le logiciel système

Objectifs

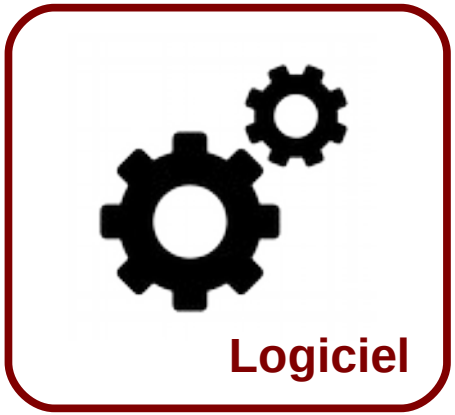

- Permettre l'administration et la gestion des milliers de composants fédérés
  - Nommage / adressage des entités
  - Configuration et mises à jour des composants (firmware)
  - Installation / déploiement / configuration des systèmes d'exploitation associés aux serveurs
  - Supervision
  - Orchestration des arrêts / démarrages
  - Définition des utilisateurs et des groupes
  - ...
- Proposer un ensemble de services aux utilisateurs
  - Développement, Exécution, Debug, Optimisation des codes de calcul séquentiels et parallèles
  - Stockage des diverses données (entrées, sorties, codes, listings, ...)
  - ...

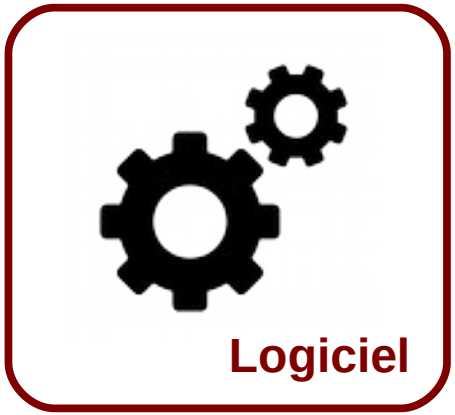

Logiciels

- Système d'exploitation
  - Majoritairement de type UNIX / LINUX
    - RedHat, CentOS, ...

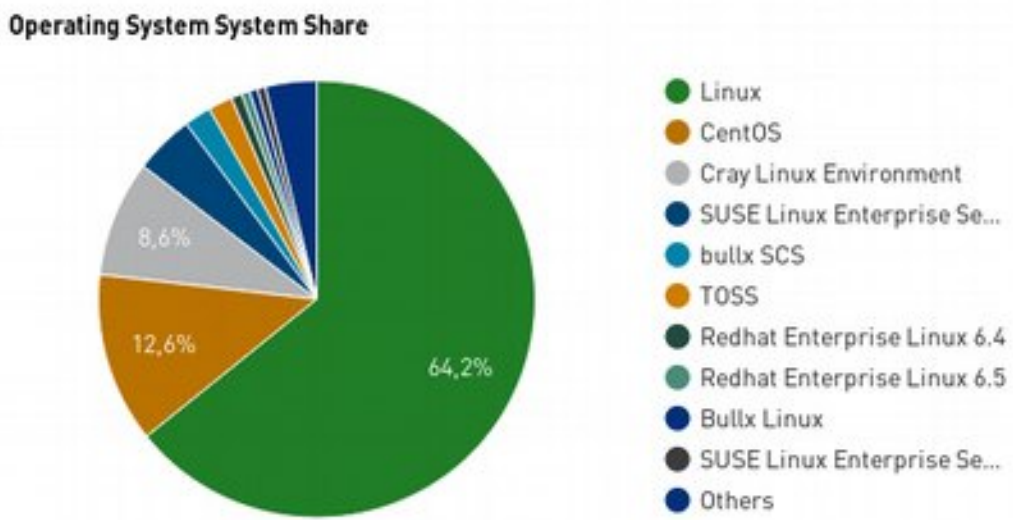

Logiciels

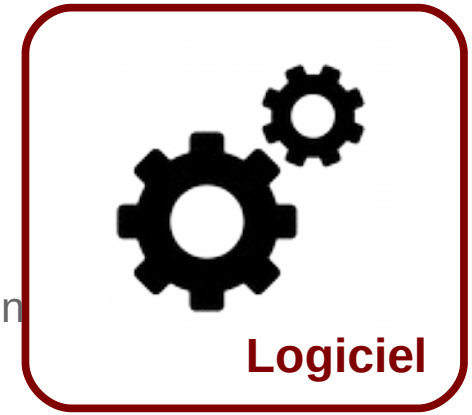

- Pile logicielle « système »
  - Librairies de communication adaptées au réseau d'interconnexion
    - Ex : drivers et libs RDMA OpenFabrics pour Infiniband
  - FS parallèle
    - Ex : Lustre
  - Gestionnaire de ressources (batch)
    - Ex : Slurm

- Pile logicielle « produits » (utilisation à la discrétion des utilisateurs)
  - Compilateurs
    - Ex : Intel C/C++, Fortran compilers
  - Environnements d'exécution parallèle
    - Ex : MPI, OpenMP, CUDA, OpenACC, UPC, ...
  - Librairies de mathématiques scientifiques
    - Ex : LAPACK, BLAS (algèbre linéaire), FFTW3 (Signal), ...
  - Librairies d'entrées/sorties avancées
    - Ex : NetCDF, HDF5, ...

Logiciels

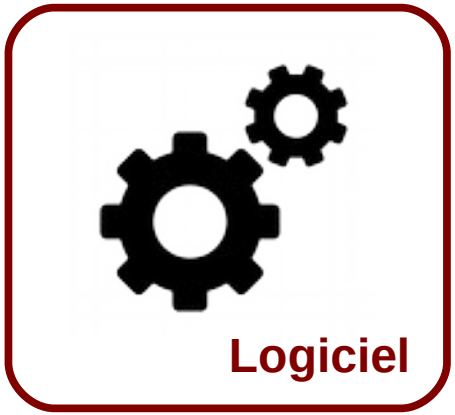

- Pile logicielle d'administration
  - Souvent propriétaire et dépendante du constructeur
    - IBM, Cray, Bull, ...
    - Enrobant bien souvent des logiciels libres
      - DNS Bind, LDAP OpenLDAP, DHCP ISC, OpenSSH, Apache HTTPD
  - Des alternatives Open-source existent
    - Mais ne sont pas toujours bien adaptées aux particularités des machines propriétaires ou à leurs tailles
    - Ex : Cobbler
  - Gestion de configuration + notion de traçabilité des évolutions (Puppet + git)

Rem :
- Réseau spécifique d'administration afin de différentier les flux d'administration différents des flux utilisateurs.
- Administration centralisée

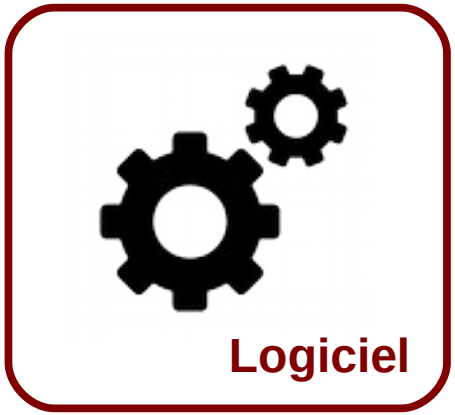

Le gestionnaire de ressources

- Intermédiaire entre l'utilisateur et le super-calculateur
  - Reçoit et traite les demandes d'exécution de calcul
    - Allocation des ressources et démarrage des applications parallèles
- Chef d'orchestre de l'utilisation du super-calculateur
  - Connaissance précise de la configuration et de l'état du système
    - Description de l'ensemble des nœuds et de leurs caractéristiques
      - Nombre de cœurs, quantité de mémoire, ...
  - Connaissance précise des demandes d'exécution des utilisateurs
    - Nombre de tâches, de coeurs/mémoire par tâche, ...
  - Connaissance précise des paramètres de répartition des ressources entre utilisateurs
    - Quotas par groupe d'utilisateur, qualités de service, ...

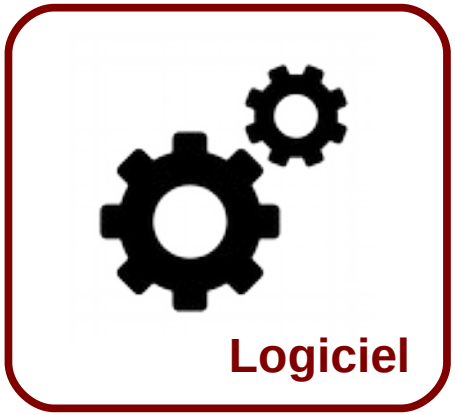

Le gestionnaire de ressources

- Point central de l'optimisation de l'usage du système
  - Placement des jobs en fonction des hiérarchies matérielles
    - Ex : NUMA intra-nœuds, topologies réseaux, ...
  - Remplissage au mieux des nœuds pour minimiser les ressources inutilisées
    - Ex : Backfill
  - Optimisation de la consommation énergétique
    - Ex : arrêt électrique des nœuds non utiles à un instant donné

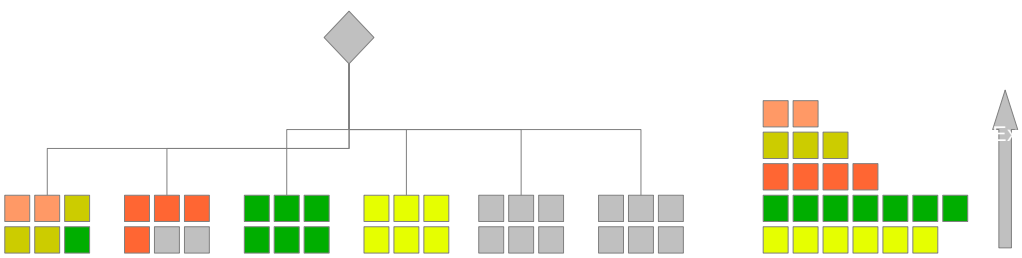

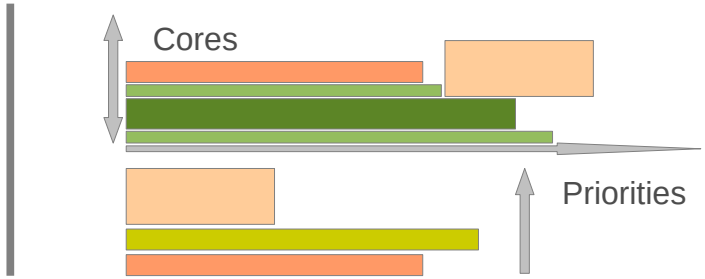

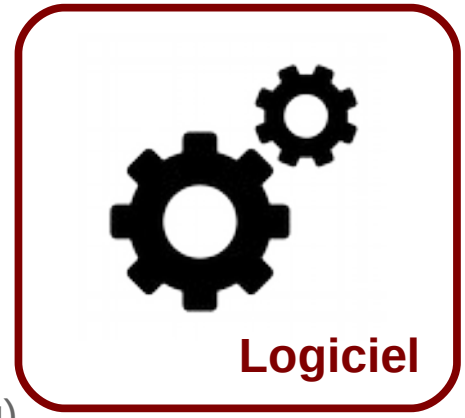

Le gestionnaire de ressources

- Différents produits disponibles
  - Propriétaires : LSF (IBM), Moab (Adaptive Computing), ...
  - Open-source : SLURM (SchedMD), Torque (Adaptive Computing), ...

- Gestionnaire de ressources utilisé au CEA : SLURM (Open-source)
  - En production sur les dernières générations de super-calculateurs déployées
    - TERA100, Curie, ...
  - Participation à la communauté depuis 2007
    - Patchs, features, meetings, ...
  - Participation à l'évolution du produit
    - Travaux communs Bull / CEA / SchedMD

Maintenance

Les principes

- Maintient en condition des différents éléments suivant un contrat de disponibilité (SLA : Service Level Agreement)

- Différents types :
  - Maintenance préventive
    - Sur taux d'erreur d'un composant (disques, mémoire, ...)
  - Maintenance corrective
    - Suite à une panne d'un élément

  Rem :

  Les notions de HA (high availibility) ou de nospof (No single point of failure) sont alors importantes

  - Maintenance évolutive
    - Mise en place de patch de sécurité, évolution système, ...

  Rem :

  Des notions de rolling upgrade (mise à jour progressive) sont en train d'apparaître

Les infrastructures

Les infrastructures

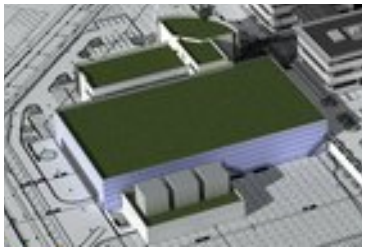

Infrastructures

Objectifs

- Accueillir l'ensemble des composants matériels
- Fournir la puissance électrique nécessaire
  - De l'ordre de plusieurs Mégawatt (MW)
    - Équivalent d'une ville de plusieurs milliers d'habitants
    - Pour alimenter le matériel informatique
    - Pour alimenter les servitudes
- Fournir la puissance de refroidissement nécessaire
  - Même ordre de grandeur que la puissance électrique
    - La plus grande partie de l'énergie électrique étant transformée en chaleur par effet Joules
- Optimiser la consommation énergétique globale
  - Notion de PUE (Power Usage Effectiveness)

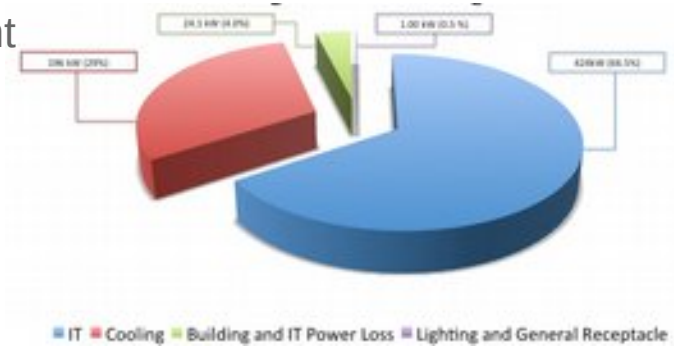

Les infrastructures

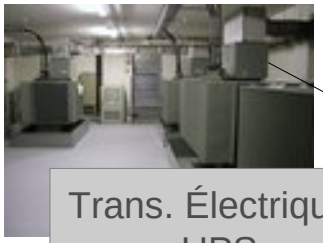

Trans. Électriques
UPS

Groupes froid

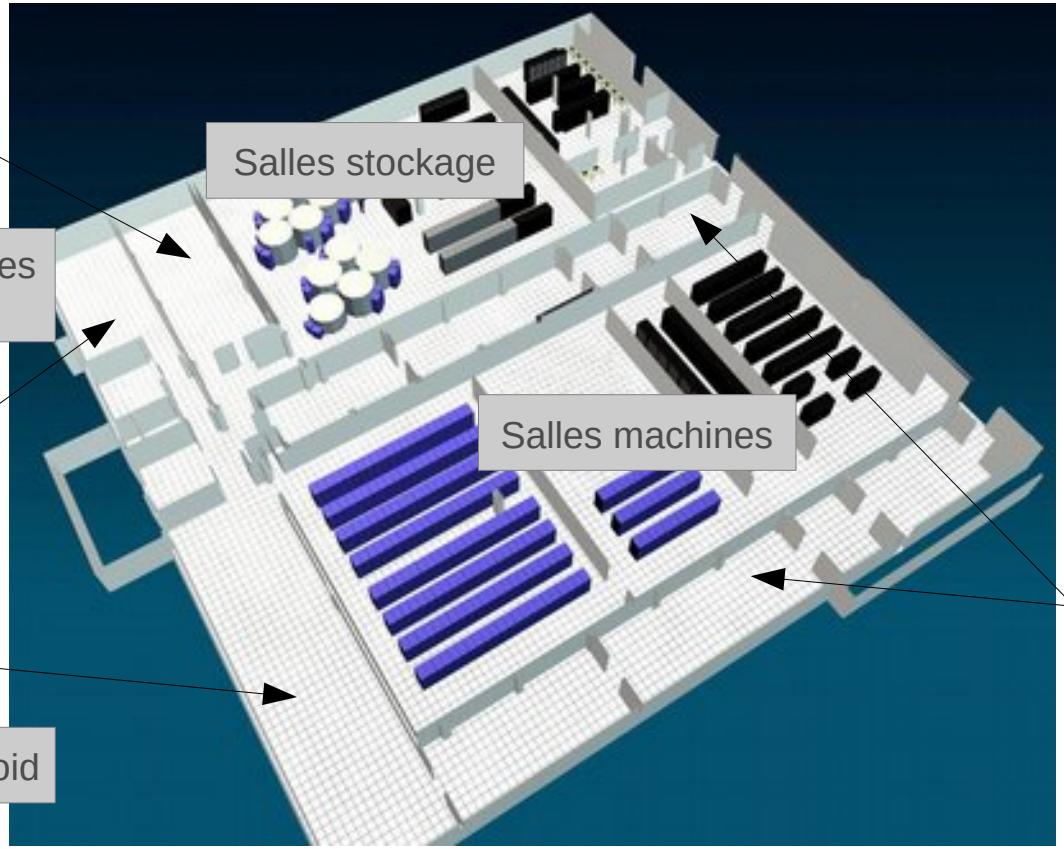

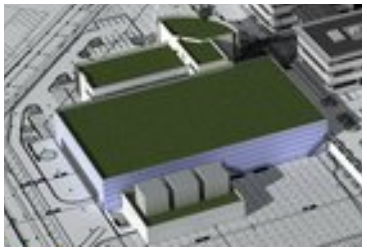

Infrastructures

Unités de traitement
De l'air

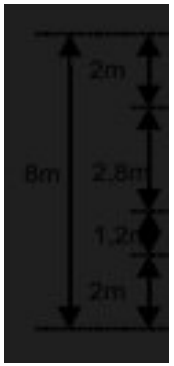

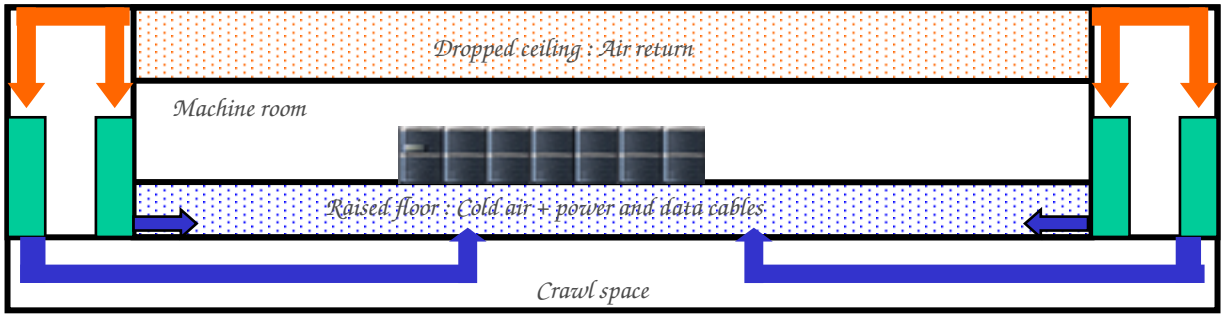

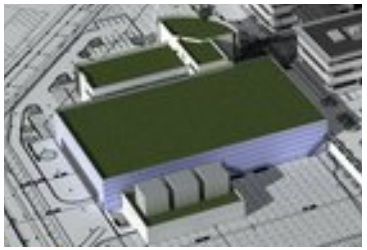

Infrastructures

Optimisation du PUE

- Co-design infrastructures - matériel
  - Réduction des pertes électriques
  - Amélioration des rendements de refroidissement

Porte froide

Alimentation
eau glacée

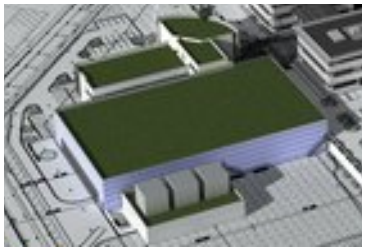

Infrastructures

Optimisation du PUE

- Refroidissement à eau chaude
  - Une eau à 35°C permet de refroidir un processeur à 60°C
    => permet de supprimer la production d'eau glacée
- Récupération de la chaleur
  - Utilisation pour le chauffage des bâtiments (pompe à caleur)
    => conception du couplage dès l'origine

Rack Sequana des machines T1K 2.X

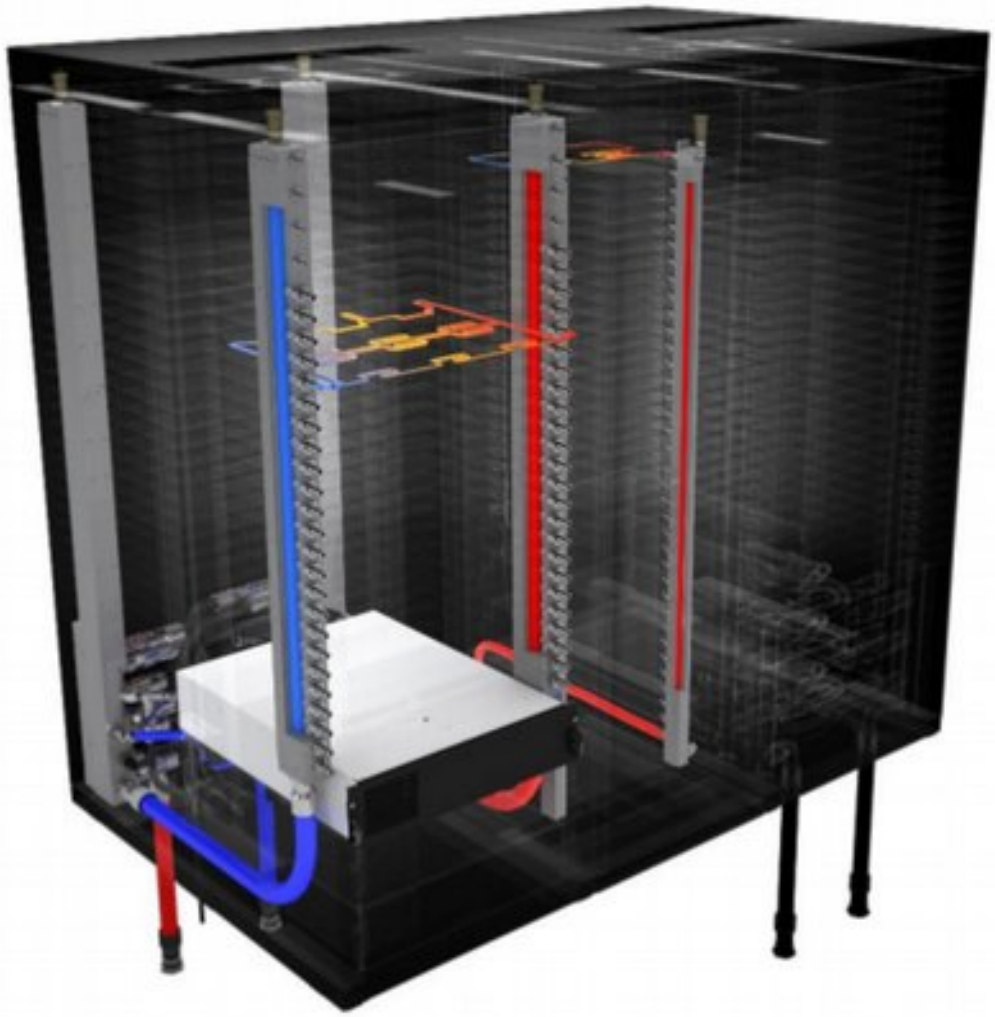

Calcul Haute Performance

Les challenges à venir

Exascale computing

- Cibles
  - Depuis 2020 (Exa = 2^{18})

- **Contraintes majeures**
  - Énergie
    - Estimations actuelles à 100 MégaWatt pour 1 système Exaflopique
      ~la consommation d'une ville de 100 000 habitants...
    - Budgets réalistes limités à une consommation de 20MW
      -> c'est à dire à peu près la consommation actuelle du système #1 Frontier (16MW)
      -> **nécessité d'un x10 des performances sans consommer un Watt de plus**
  - Taille des systèmes
    - Limite des performances unitaires des unités de calcul
    - **Augmentation très importante du nombre de cœurs et de nœuds**
      -> **conséquences importantes sur toutes les piles logicielles et les codes de calcul eux-mêmes**

It is not just "exaflops" – we are changing the whole computational model

Current programming systems have WRONG optimization targets

Old Constraints

- **Peak clock frequency** *as primary limiter for performance improvement*
- **Cost:** *FLOPs* are biggest cost for system: *optimize for compute*
- **Concurrency**: Modest growth of parallelism by adding nodes
- **Memory scaling**: *maintain byte per flop capacity and bandwidth*
- **Locality**: *MPI+X model (uniform costs within node & between nodes)*
- **Uniformity**: *Assume uniform system performance*
- **Reliability**: *It's the hardware's problem*

New Constraints

- **Power** *is primary design constraint for future HPC system design*
- **Cost:** *Data movement dominates: optimize to minimize data movement*
- **Concurrency:** *Exponential growth of parallelism within chips*
- **Memory Scaling:** *Compute growing 2x faster than capacity or bandwidth*
- **Locality**: *must reason about data locality and possibly topology*
- **Heterogeneity**: *Architectural and performance non-uniformity increase*
- **Reliability**: *Cannot count on hardware protection alone*

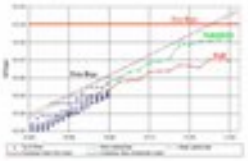

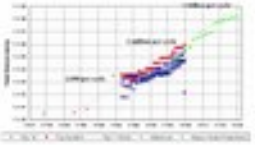

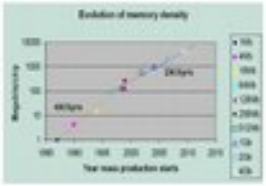

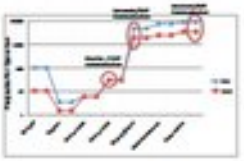

Fundamentally breaks our current programming paradigm and computing ecosystem

35

Intelligence Artificielle appliquée aux applications

- Entraînement sur des grands volumes de données
  - entraînement de Pl@ntNet : 370 000 espèces, 60 000 cœurs, 12h d'entraînement
    - https://www.genci.fr/sites/default/files/Fiche%20PlantNet-Bd%20Vf.pdf
- Apprentissage automatique pour l'analyse de données massives (ex : LHC, SKA, LIGO/VIRGO)
  - Utilisation du deep-learning dans les pipelines d'analyse de données du CERN
    - https://atlas.cern/updates/briefing/search-new-particles-machine-learning,
    - https://home.cern/news/news/computing/cern-skao-geant-and-prace-collaborate-high-performance-computing
- Utilisation en remplacement de modèles sous-maille (« super résolution »)
  - Simulations dites directes (résolution suffisante pour résoudre physiquement le problème) très coûteuses
    - utilisation de modèles sous-mailles : résolution plus basse et paramétrisation de certains phénomènes physiques
    - substitution des modèles sous-maille par des réseaux neuronaux entraînés sur des simulations haute résolution
    - https://cerfacs.fr/ddm-data-science-intelligence-artificielle-2/,
    - https://www.surf.nl/files/2020-03/white-paper-dl4hpc-.pdf

Intelligence Artificielle appliquée à la gestion des machines

- Récupération d'un maximum de données du centre de calculM
  - Mise en place d'un cluster de « statistiques » (80 nœuds, 7 milliards d'événements par jour)
  - Analyse de ces données
- Cognitive Data Center
  - Analyse de l'état du centre de calcul
  - Détection de pannes ou d'anomalies, alertes, actions correctives, …
- Optimisation du coût énergétiques des infrastructures
  - Power Usage Effectiveness (PUE ~ 1.0)
  - Proposition d'allocation optimisée de ressources
- Détection de comportements inadaptés de codes
  - Sécurité
  - Code mal paramétré
- Prédiction de performances des codes
  - Temps IO, etc..

Machines Quantiques

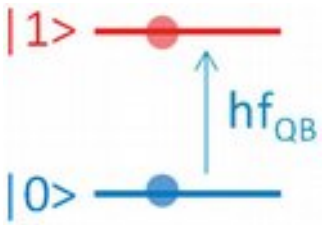

- Qu'est-ce que c'est ?
  - Informatique classique : bit (0, 1) + portes logiques
  - Informatique quantique : qbit (0 et 1 ; on peut avoir des états intermédiaires entre 0 et 1) + portes quantiques
  - Cette superposition d'états intermédiaires permet de conduire des calculs en // donc plus rapidement

- Plan quantique français : 1,8 Milliards sur 5 ans
  - CEA, CNRS, INRIA, Universités Paris-Saclay, Grenoble,
  - ATOS, Thalès, Total, EDF, DGA
  - Pasqal, Quandela

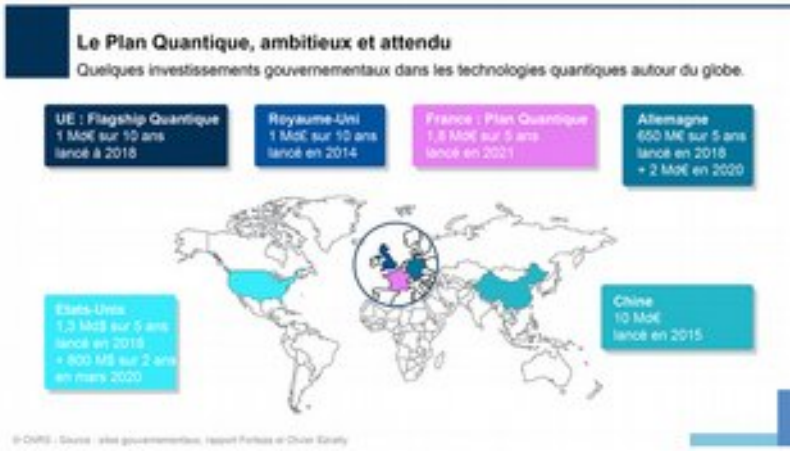

- Principaux usages envisagés :
  - physique des matériaux, chimie quantique
  - apprentissage automatique
  - cryptographie
  - base de données (recherche)

Organisation en différentes thématiques

Applications

Sécurité

Exploitation

Utilisabilité

Fiabilité

I/O

Adaptabilité

2 approches

- Évolution en continu du centre de calcul
- R&D long terme

Centre de calcul

Centre de calcul futur

Questions

Commissariat à l'énergie atomique et aux énergies alternatives
Centre DAM Ile-de-France | Bruyères-le-Châtel 91297 Arpajon Cedex
T. +33 (0)1 69 26 40 00 |
Etablissement public à caractère industriel et commercial | RCS Paris B 775 685 019

DAM/DIF