Utilisation de l'IA dans la cyber sécurité

Table des matières

1. Introduction
2. Attaques d'IA
   - Attaque par exemple contradictoire
   - Attaque sur un détecteur d'attaques
3. Pratique ?

Table of content

1. Introduction
2. Attaques d'IA
   - Attaque par exemple contradictoire
   - Attaque sur un détecteur d'attaques
3. Pratique ?

Géopolitique

- Japon : aucune loi sur le copyright

Géopolitique

- Japon : aucune loi sur le copyright
- Etats-Unis : création de lois et recommandations

Safe and Effective Systems

Algorithmic Discrimination Protections

Data Privacy

Notice and Explanation

Human Alternatives, Consideration, and Fallback

IA pour la défense

Utilisations de l'IA dans la défense :

- Détection de spamms ($\sim$ 1960)

IA pour la défense

Utilisations de l'IA dans la défense :

- Détection de spamms ($\sim$ 1960)
- Détection d'anomalies sur un réseau (2000)

IA pour la défense

Utilisations de l'IA dans la défense :

- Détection de spamms ($\sim$ 1960)
- Détection d'anomalies sur un réseau (2000)
- Détection de failles dans du code

IA pour la défense

Utilisations de l'IA dans la défense :

- Détection de spamms ($\sim$ 1960)
- Détection d'anomalies sur un réseau (2000)
- Détection de failles dans du code
- Reverse et détection de malwares $\rightarrow$ Google Sec-PaLM

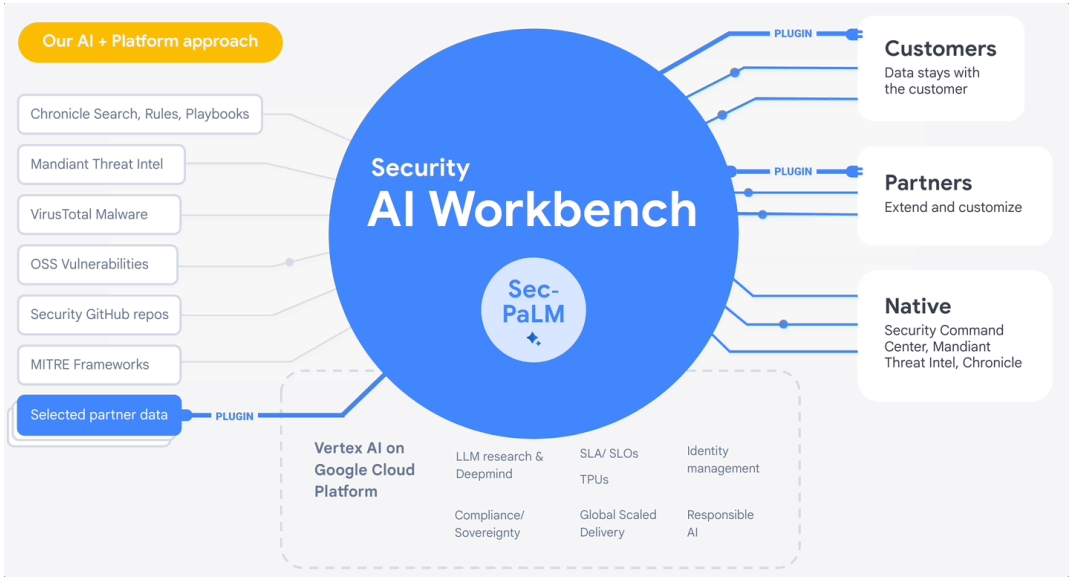

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres
- Phishing : automatisation, spear phishing

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres
- Phishing : automatisation, spear phishing
- Web : trouver des urls

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres
- Phishing : automatisation, spear phishing
- Web : trouver des urls
- Botnet : meilleure coordination

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres
- Phishing : automatisation, spear phishing
- Web : trouver des urls
- Botnet : meilleure coordination
- Cacher des malwares dans des images

IA pour l'attaque

Utilisations de l'IA pour tapper :

- Tapper toutes les défenses qui utilisent l'IA
- Détecter un code pin, un code de carte de crédit grâce au microphone et aux accéléromètres
- Phishing : automatisation, spear phishing
- Web : trouver des urls
- Botnet : meilleure coordination
- Cacher des malwares dans des images
- ...

Table of content

1 Introduction

2 Attaques d'IA
- Attaque par exemple contradictoire
- Attaque sur un détecteur d'attaques

3 Pratique ?

Attaques d'IA

Trois types d'attaques :

Attaques d'IA

Trois types d'attaques :

Falsification des données

Attaques d'IA

Trois types d'attaques :

Falsification des données

Extraction de données

Attaques d'IA

Trois types d'attaques :

Falsification des données

Extraction de données

Attaques par exemple contradictoire

Kéceucé un classifieur ?

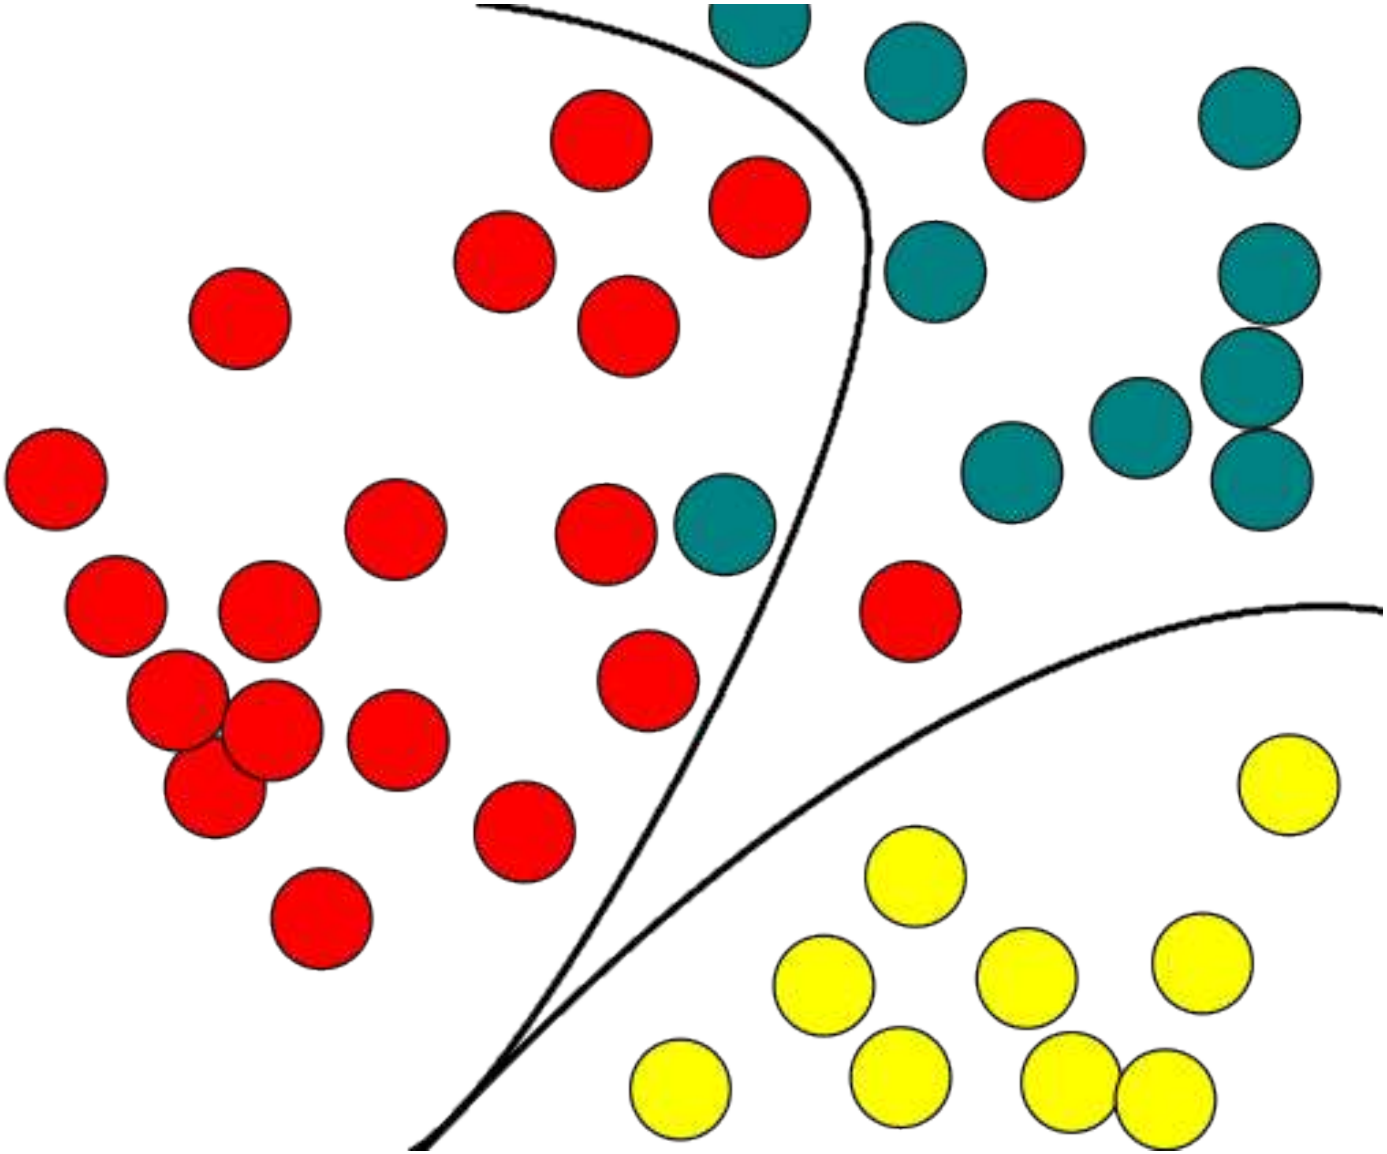

Norme L_∞

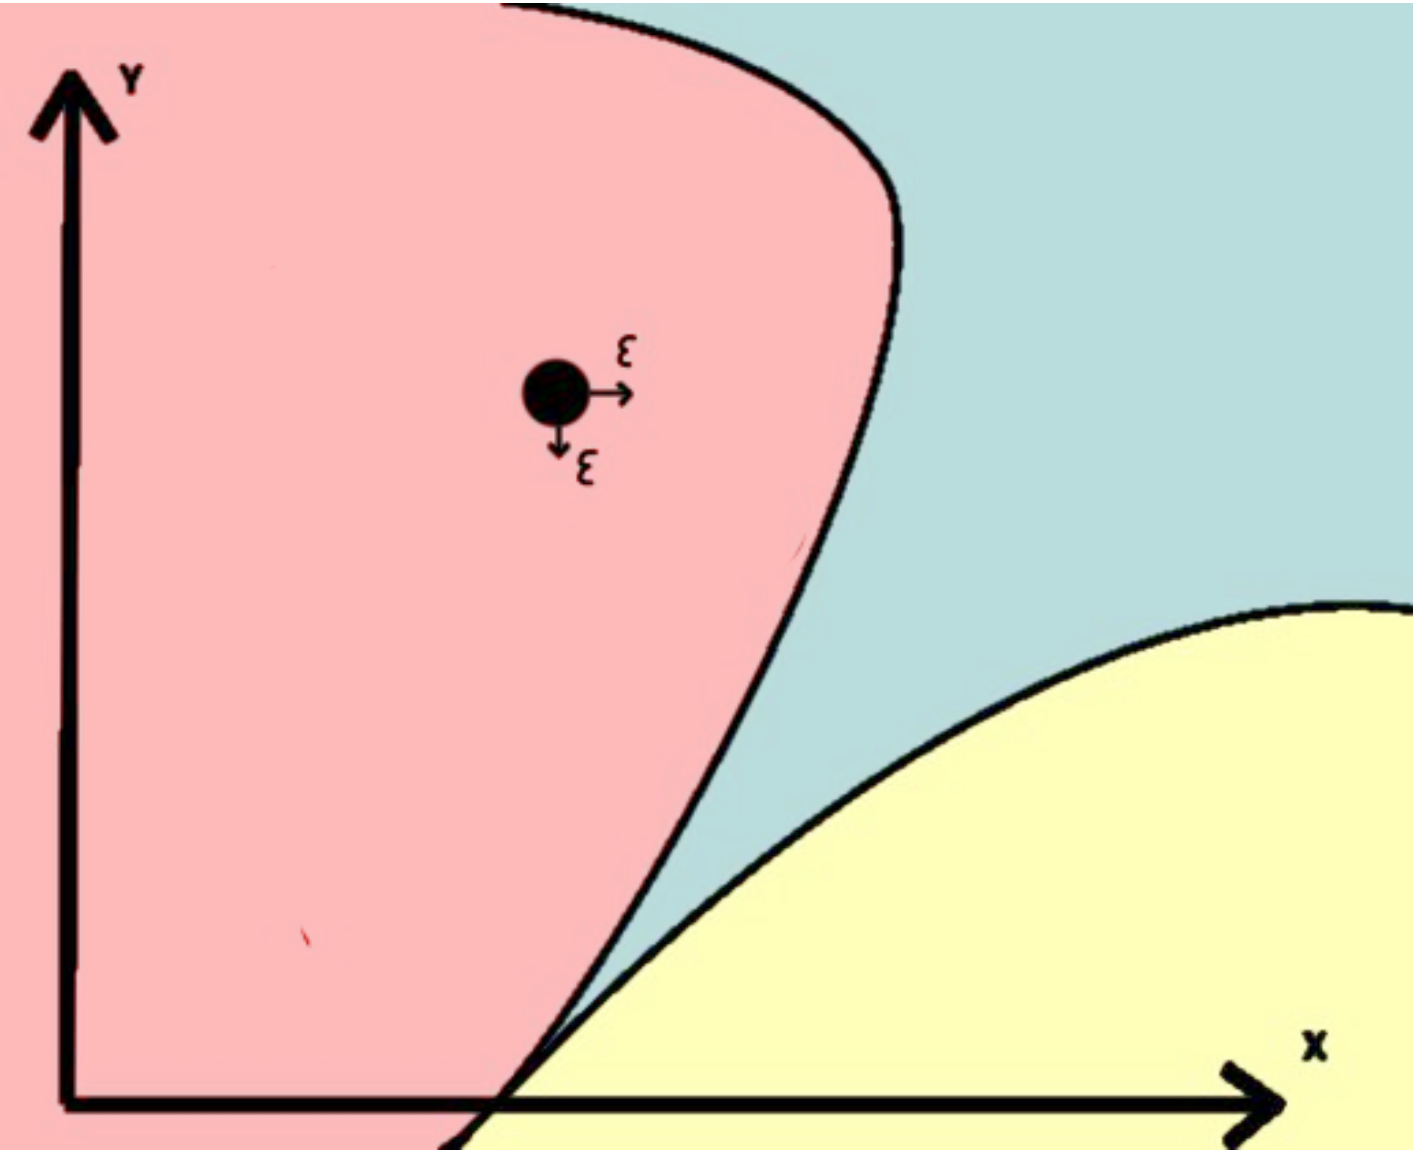

Norme L_2

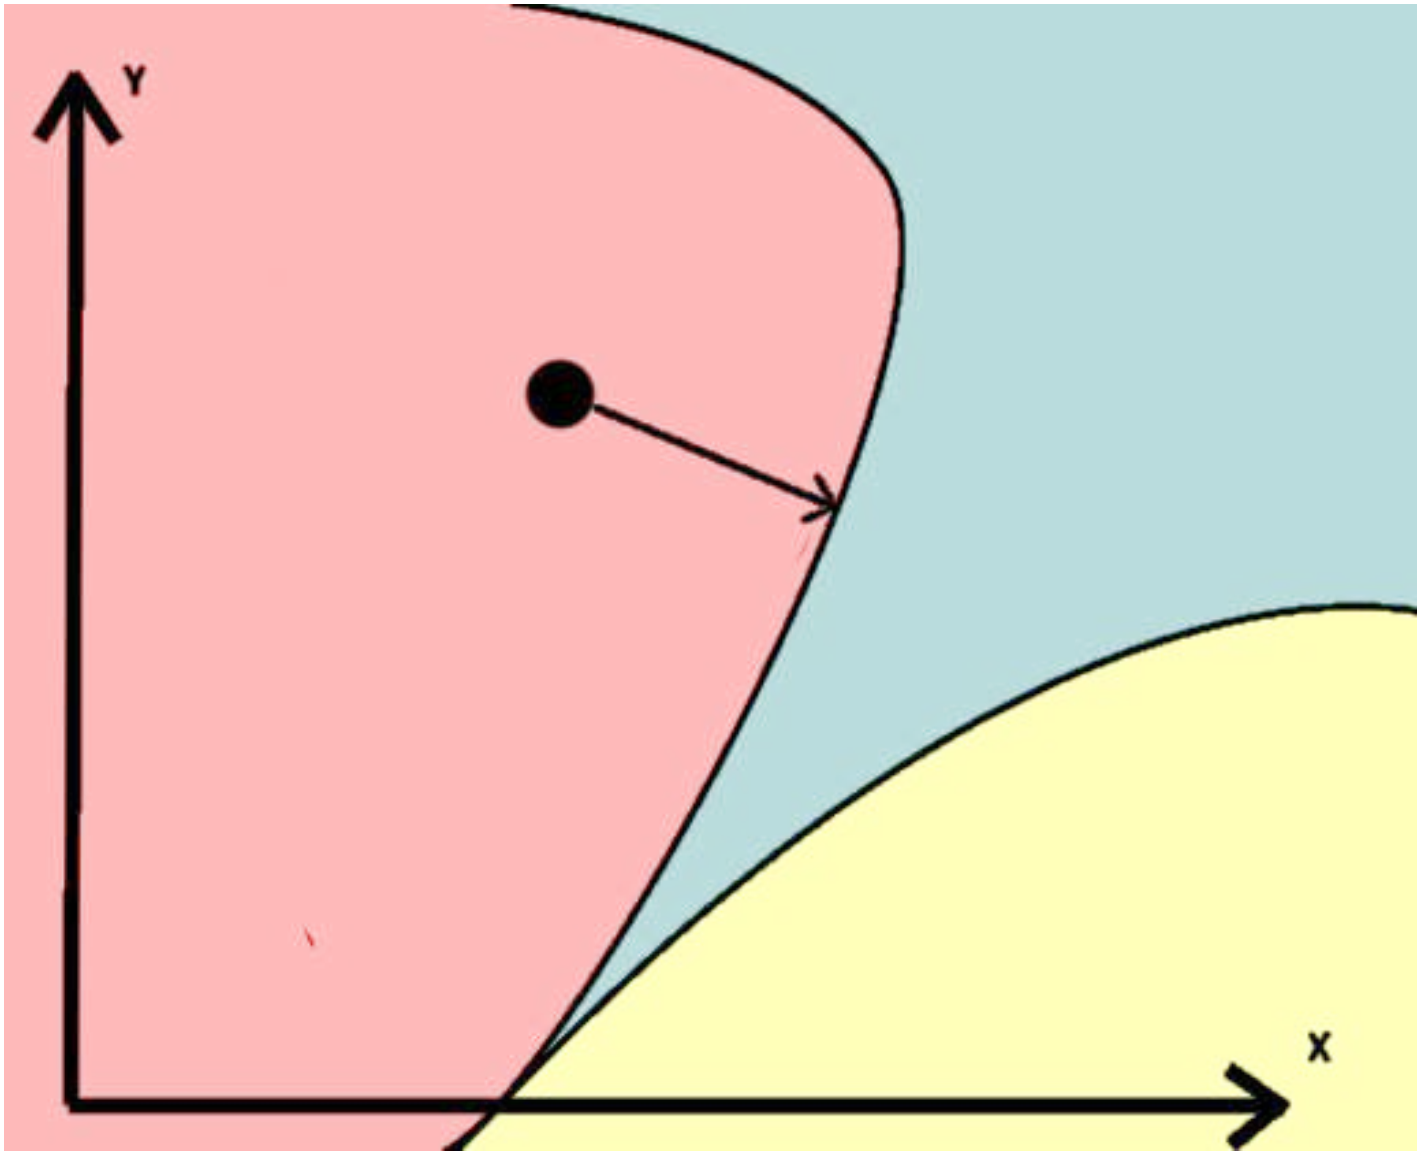

Norme L_0

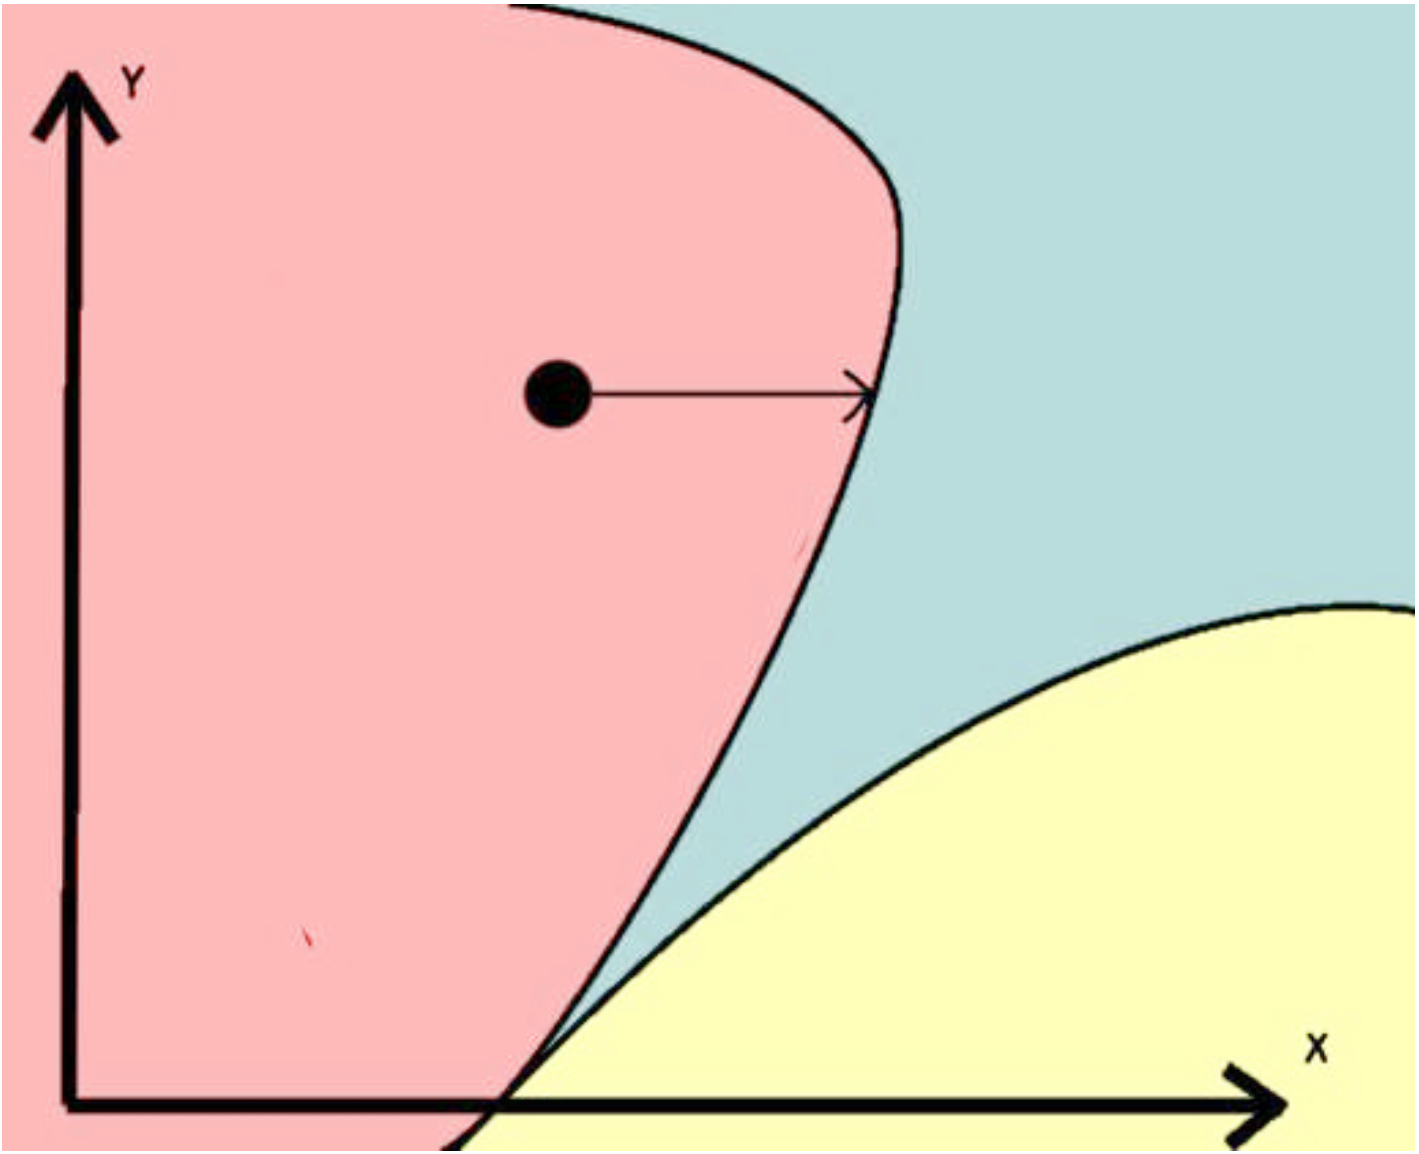

Attaques par exemple contradictoire

Boite blanche

- FGSM (Fast Gradient Sign Method) : L_∞

Attaques par exemple contradictoire

Boite blanche

- FGSM (Fast Gradient Sign Method) : L_∞
- BIM (Basic Iterative Method) : L_∞

Attaques par exemple contradictoire

Boite blanche

- FGSM (Fast Gradient Sign Method) : L_∞
- BIM (Basic Iterative Method) : L_∞
- JSMA (Jacobian-based Saliency Maps Attacks) : L_0

Attaques par exemple contradictoire

Boite blanche

- FGSM (Fast Gradient Sign Method) : L_∞
- BIM (Basic Iterative Method) : L_∞
- JSMA (Jacobian-based Saliency Maps Attacks) : L_0
- DF (DeepFool) : L_2

Attaques par exemple contradictoire

Boite blanche

- FGSM (Fast Gradient Sign Method) : L_∞
- BIM (Basic Iterative Method) : L_∞
- JSMA (Jacobian-based Saliency Maps Attacks) : L_0
- DF (DeepFool) : L_2
- CW (Carlini and Wagner) : L_∞, L_0, L_2

Attaques par exemple contradictoire

Boite noire

- ZOO (Zeroth Order Optimisation attack)
- TAA (Transferable Attentive Attack)
- AI-GAN (Attack Inspired GAN)

Exemples

Attaque FGSM (L_∞):

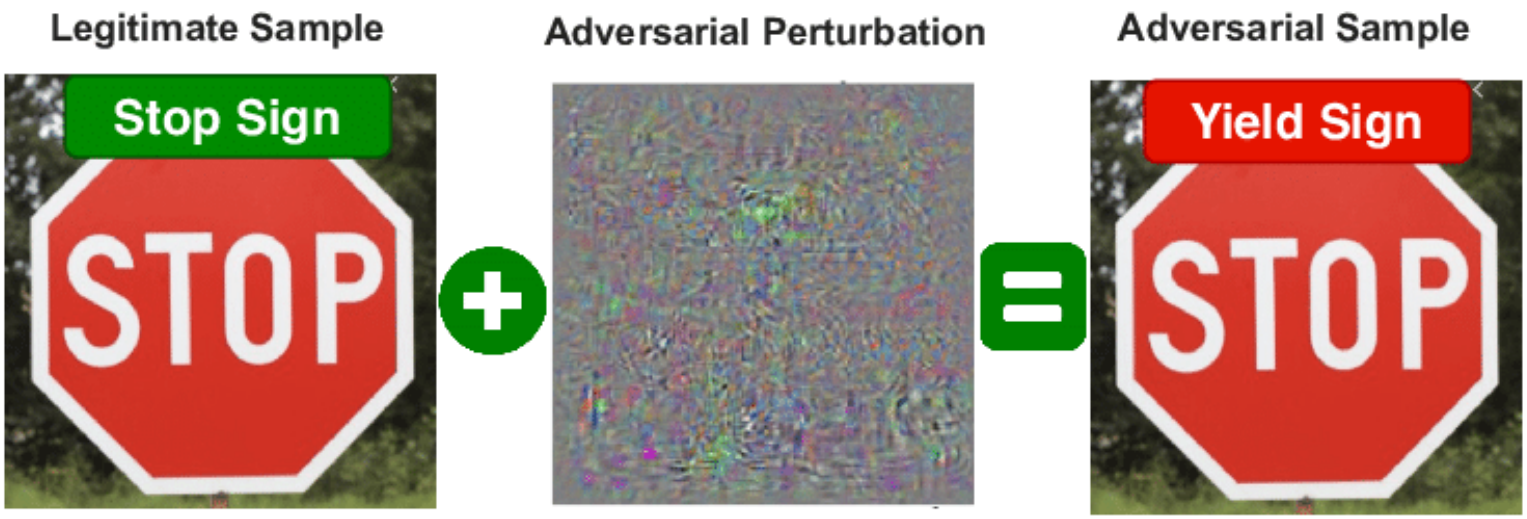

Figure: Ahmad et al. 2021

Exemples

Attaque JSMA (L_0):

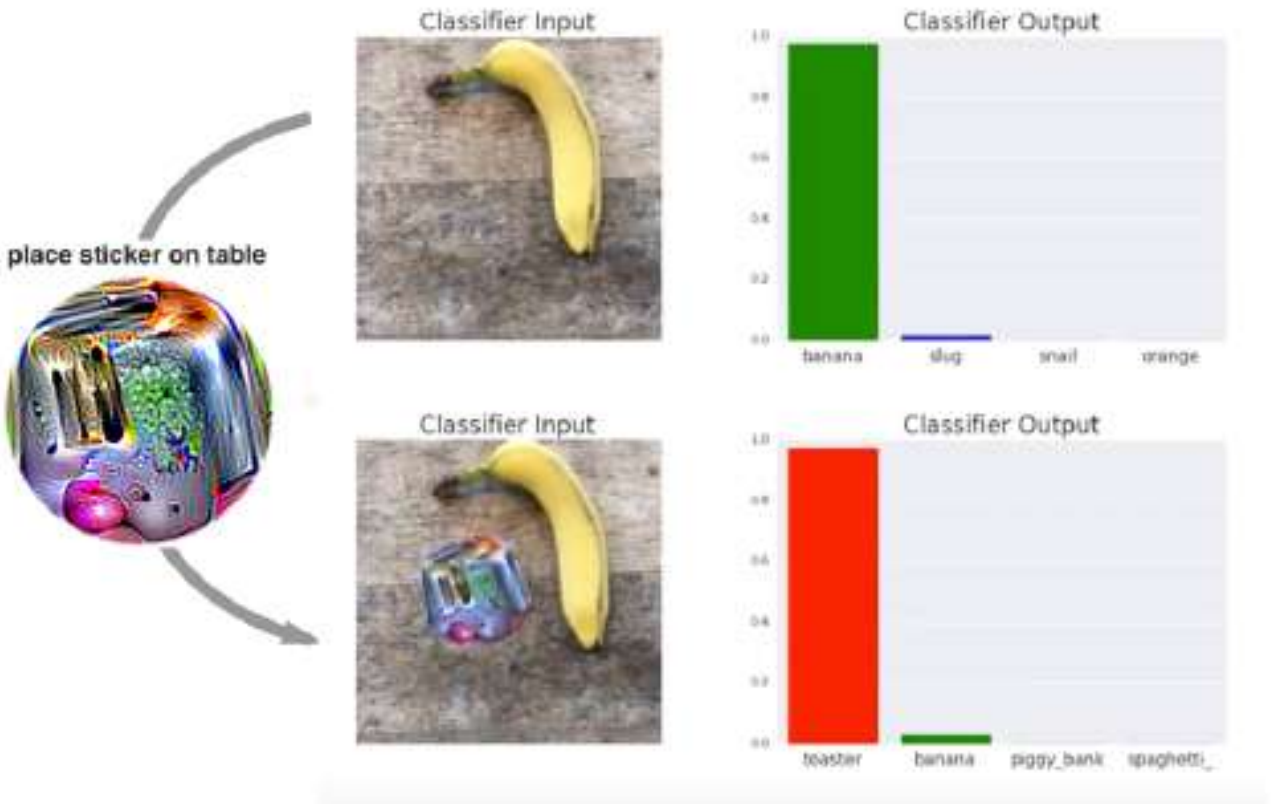

Figure: Brown et al. 2018

Cassage de protection réseau

Utilisation de l'IA pour la détection d'intrusions

Cassage de protection réseau

Utilisation de l'IA pour la détection d'intrusions Base de donnée utilisée :

- NSL-KDD (1998)
- UNSW-NB 15 (2015)
- CIDDS-001 (2017)

Cassage de protection réseau

Utilisation de l'IA pour la détection d'intrusions Base de donnée utilisée :

- NSL-KDD (1998)
- UNSW-NB 15 (2015)
- CIDDS-001 (2017)

```
0,tcp,private,REJ,0,0,0, ... ,1.00,anomaly
2,tcp,ftp_data,SF,12983,0,0, ... ,0.00,normal
```

Expériences et résultats

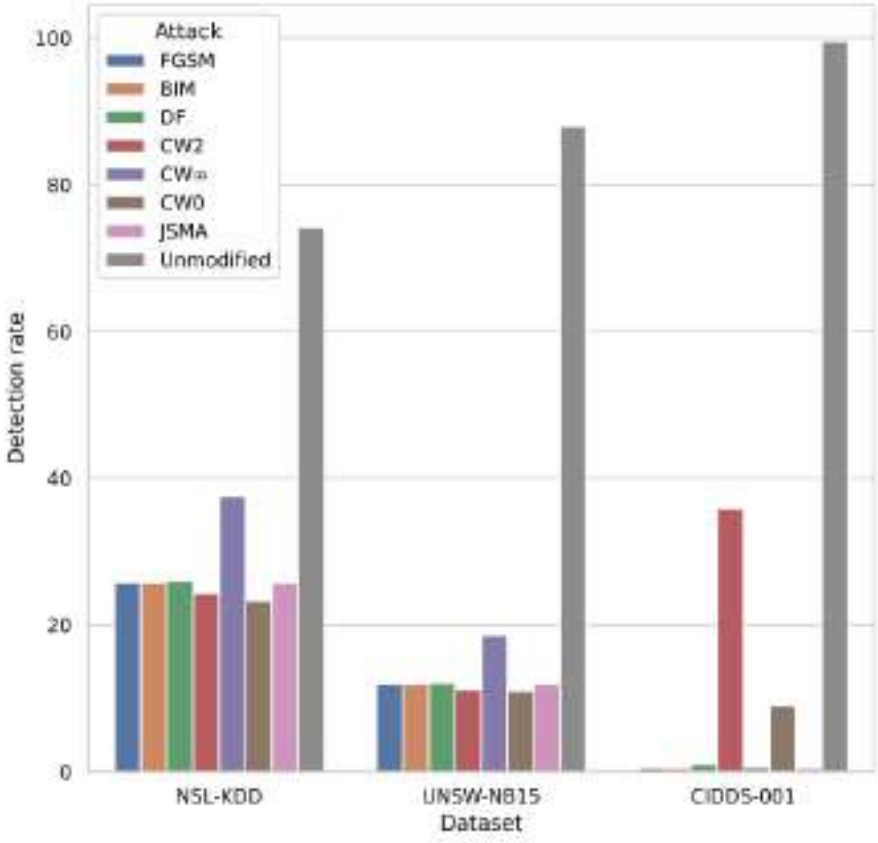

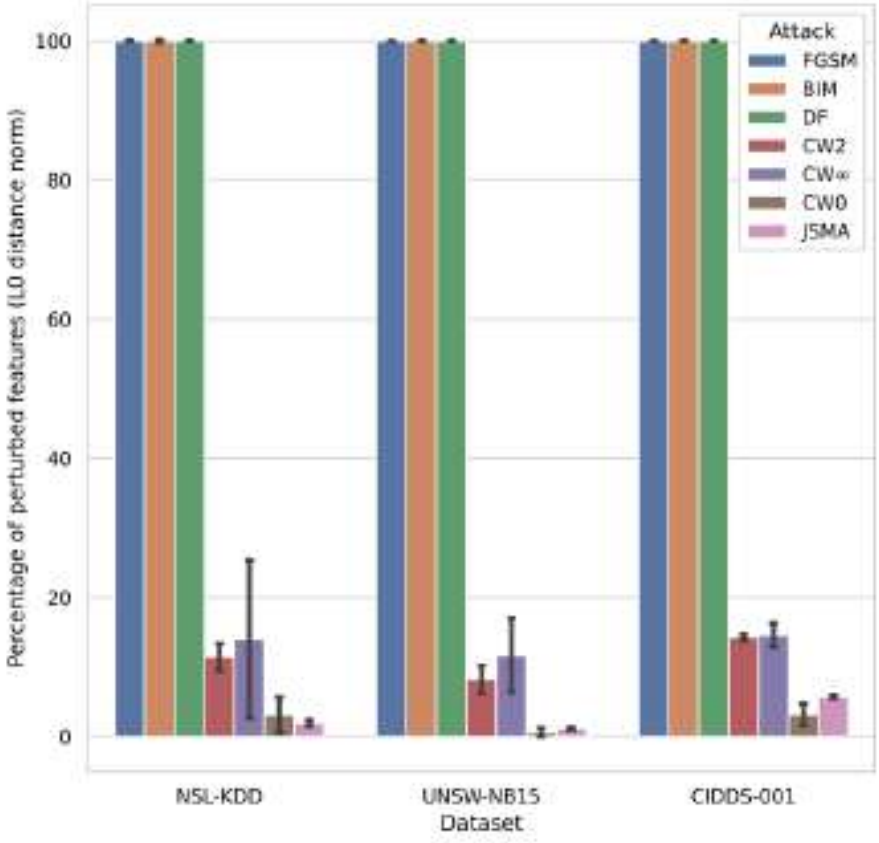

Figure: Pourcentage de détection par la défense et nombre de caractéristiques perturbées

Expériences et résultat

Problème : quand les données ont du sens il est difficile de les "perturber"

- Plage de valeurs non valide
- Valeurs binaires non valides ($\{0, 1\} \rightarrow [0, 1]$)
- Appartenance à une catégorie non valide
- Relations sémantiques non valides

Expériences et résultat

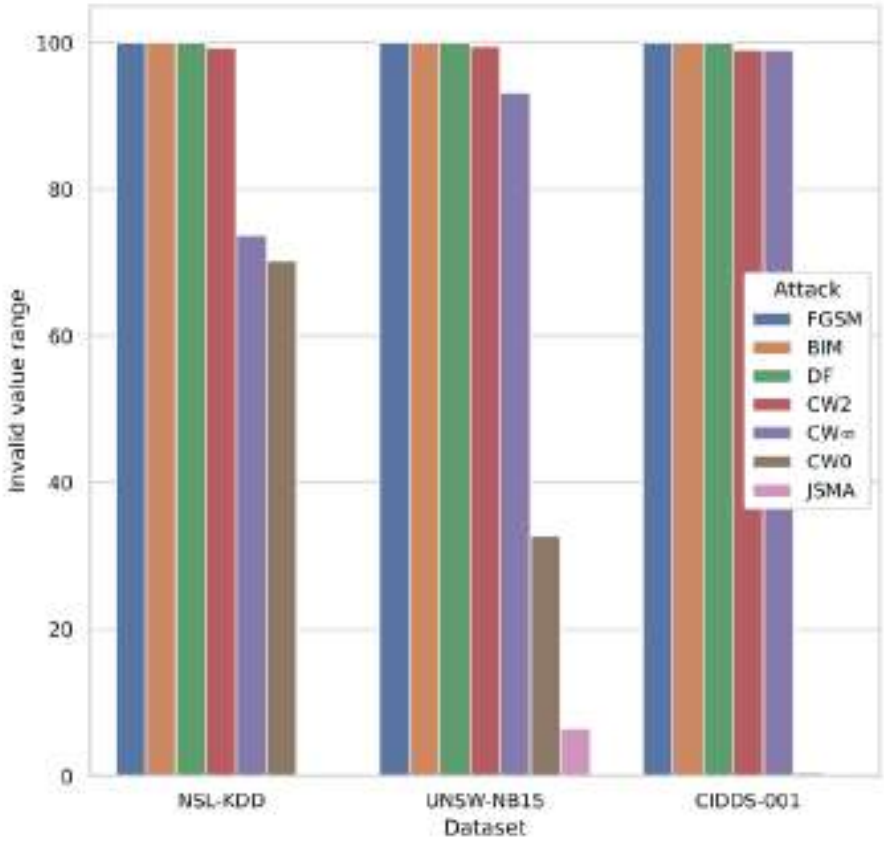

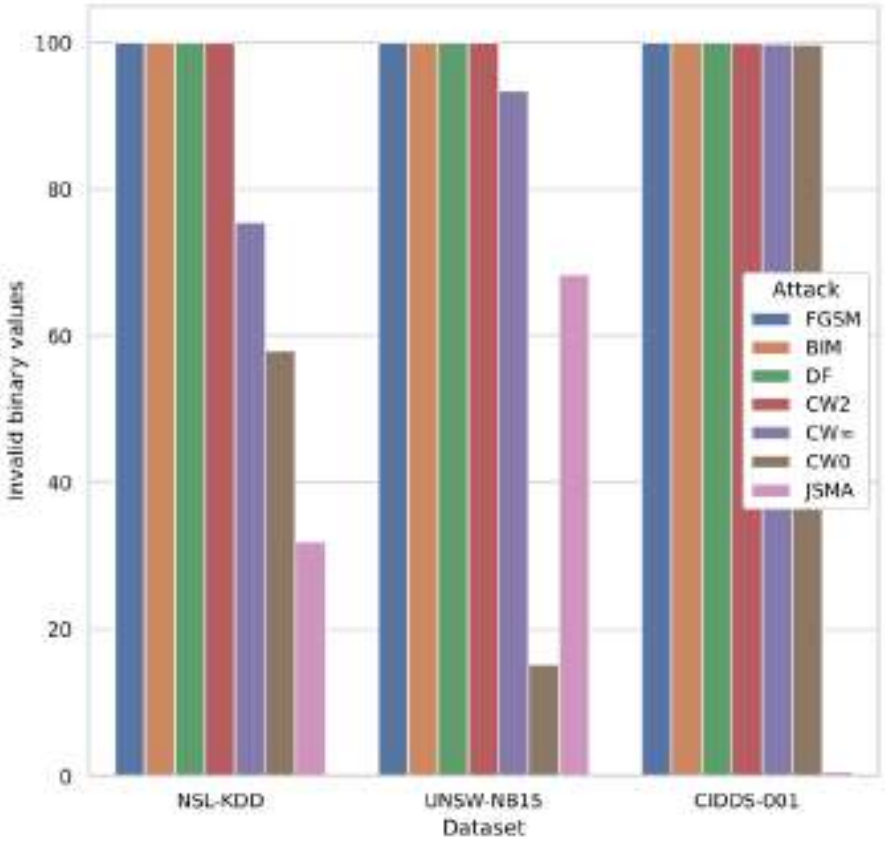

Figure: Pourcentage d'exemples contradictoires avec de mauvaises plages de valeurs / de mauvaises valeurs binaires

Table of content

1. Introduction
2. Attaques d'IA
   - Attaque par exemple contradictoire
   - Attaque sur un détecteur d'attaques
3. Pratique ?